ALEPH 과제 10 · AI 와 함께 쓰는 첫 논문

# 프롬프트의 구조적 요소가 AI 의 지시 준수율에 미치는 영향

아홉 가지 요소를 두 모델에서 비교한 통제 실험

**김민석**

2026 년 10 월 25 일

주 모델: gemini-3.5-flash-lite (Gemini API 무료 등급), gpt-6-luna (OpenAI API)

## 초록

프롬프트에 어떤 구조적 요소를 더하느냐에 따라 대규모 언어 모델의 지시 준수율이 달라지는지를 실험으로 확인했다. 일반 사용자가 쓰는 기본 등급 모델 두 개(Gemini API 무료 등급의 gemini-3.5-flash-lite, ChatGPT 무료 서비스의 기본 모델인 gpt-6-luna)를 대화 기록 없는 단일 메시지로 호출했다. 한국어 안내문 작성 과제 10 개에 형식·구조 지시 8 개를 주고, 기본 조건과 아홉 가지 요소(형식 지정, 번호 분할, 제약 명시, 예시 제시, 역할 부여, 출력 길이 지정, 핵심 지시 맨 앞, 핵심 지시 맨 끝, 자기 점검 요청)를 지시 준수율로 비교했다. gemini-3.5-flash-lite 는 처음 300 회(조건당 30 쌍)로 분석을 확정한 뒤 700 회를 더해 10 세트(조건당 100 쌍)로 합산했고, gpt-6-luna 는 10 세트(1,000 회)를 호출했다.

gemini-3.5-flash-lite 에서 기본보다 뚜렷하게 높았던 것은 예시 제시 하나였다. 처음 300 회에서 기본 73.3%가 예시 제시로 90.0%(+16.7%p, 95% 부트스트랩 구간 +11.7~+22.5, Holm 보정 순열검정 p<0.001)가 됐고, 10 세트 합산에서도 69.5%에서 87.9%(+18.4%p, 구간 +15.0~+21.8, Holm p<0.001)였다. 나머지 여덟 요소는 10%p 기준으로 기본과 구분되지 않았다. 예시는 소제목 수, 문단 수, 해요체처럼 눈에 보이는 구조·문체 지시를 거의 모두 지키게 했지만 전체 문장 수 지시는 개선하지 못했다. 내용 없는 형식 틀만 보여 줘도 효과가 비슷했다(예시 변형 120 쌍: 예시 1 개 +21.6%p, 형식 틀 +20.2%p).

이 효과는 예시 글의 길이나 내용, 특정 예시 하나로는 설명되지 않았다. 예시와 같은 내용이지만 형식이 없는 줄글은 기본 대비 -4.5%p, 길이만 비슷한 무관한 글은 +0.6%p 였고 예시 제시보다 각각 25%p, 19.9%p 낮았다. 주제와 문장 구성이 다른 예시 두 개는 기본보다 +20.5%p, +17.5%p 높아 도서관 예시(+20.2%p)와 비슷했다(gpt-6-luna 에서는 예시 세 개 모두 +2.4~+4.0%p 로 올랐으나 10%p 기준에는 못 미쳤다). 안내문이 아닌 글 8 종에서도 방향은 같았다(+15.9%p). 예시가 지시와 어긋나면 모델에 따라 달랐다. gemini-3.5-flash-lite 는 합니다체 예시를 받자 해요체 지시 통과율이 정상 예시의 97.0%에서 74.0%로 떨어졌지만 gpt-6-luna 는 지시를 따랐다.

gpt-6-luna 는 기본 준수율이 이미 96.9%여서 아홉 요소 어느 것도 기본과 구분되지 않았고 예시 제시는 +2.0%p(Holm p=0.571)에 그쳤다. 지시를 12 개로 늘려도 기본 준수율은 97.4%로 같았고 어느 요소도 10%p 이상 차이가 나지 않았다. 다른 소형 모델(gemini-3.1-flash-lite +12.5%p, gpt-5.6-luna +6.3%p)에서도 방향은 같았고 기본 준수율이 높을수록 효과가 작았다.

내용 점검은 판정 방법에 따라 엇갈렸다. 작은 심판 모델(gemma)은 예시 조건의 글을 덜 선호했고(승률 16.7%, 구간 6.7~28.3), 숫자·이름의 일치로 센 사실 보존율도 기본 95.0%에서 예시 제시 87.8%로 낮았다(30 쌍, 사후 분석). 그러나 응답을 만든 회사와 다른 회사의 모델이 사실 목록으로 100 쌍씩 점검한 결과에서는 사실 보존율에 차이가 없었다(gemini-3.5-flash-lite 응답 96.27%에서 95.32%, gpt-6-luna 응답 99.65%에서 100.00%).

결과는 소형·기본 등급 모델과 한국어 글쓰기 과제에 한정되며, API 기본 설정으로 호출한 값이다. 기본 조건의 난이도를 gemini-3.5-flash-lite 에 맞춰 지시를 여러 차례 조정한 예비 실험 과정과, 반복·보강 실험이 주 실험 결과를 본 뒤에 설계된 것임을 함께 보고한다.



**키워드** 프롬프트 설계, 지시 준수, 예시 제시, 대규모 언어 모델, 통제 실험

# 1. 서론

## 1.1 배경

AI 에게 일을 시킬 때 사람들은 결과의 형식을 지정하고, 지시에 번호를 붙이고, 금지할 것을 따로 적고, 예시를 보여 주고, 역할을 맡기고, 마지막에 스스로 점검하라고 덧붙인다. 이런 요령은 널리 퍼져 있지만 실제로 지시를 더 잘 지키게 하는지, 그리고 어느 것이 더 효과적인지는 모델과 과제에 따라 달라서 직접 재어 보지 않으면 알기 어렵다.

관련 연구는 여러 갈래다. 프롬프트의 형식이 성능에 영향을 준다는 보고가 있고(He et al., 2024), 의미와 무관한 서식 차이만으로도 결과가 크게 달라진다는 보고가 있다(Sclar et al., 2023). 지시 준수는 규칙으로 자동 점검할 수 있는 지시를 만들어 평가하는 방식이 쓰였고(Zhou et al., 2023), 긴 입력에서 정보의 위치가 활용도에 영향을 준다는 연구가 있다(Liu et al., 2024). 시스템 프롬프트에 역할(페르소나)을 주는 것이 성능을 일관되게 높이지 않는다는 보고(Zheng et al., 2024), 예시를 주는 방식이 언어 모델의 과제 수행을 끌어올린다는 보고(Brown et al., 2020), 스스로 결과를 점검하고 고치게 하는 방식(Madaan et al., 2023)도 있다. 이 연구는 이들 요령을 두 모델과 한 과제 묶음 안에서 같은 기준으로 나란히 비교한다.

## 1.2 연구 질문과 가설

**가설** 프롬프트에 포함하는 구조적 요소의 종류에 따라 AI 의 지시 준수율이 달라진다.

귀무가설은 어떤 요소를 더해도 지시 준수율이 기본 조건과 같다는 것이다. 이 연구는 각 요소를 기본 조건과 비교해 차이의 크기와 불확실성을 추정하고, 어느 요소가 기본과 구분되는지를 순위로 보고한다.

## 1.3 이 연구의 범위

- 주 모델은 두 개다. gemini-3.5-flash-lite(Gemini API 무료 등급)와 gpt-6-luna(OpenAI API)이며 모두 일반 사용자가 기본으로 쓰는 소형·기본 등급 모델이다. 반복·보강 실험에서 다른 소형 모델 두 종류(gemini-3.1-flash-lite, gpt-5.6-luna)를 더 확인했으나 널리 쓰이는 대형 모델에는 일반화하지 않는다.
- 과제는 한국어 글쓰기 10 개(안내문, 이메일, 공지, 보고서, 문자 등)이며, 지시는 규칙으로 점검할 수 있는 형식·구조·문체 지시 8 개다. 보강 실험(3.8)에서 설명문, 후기, 일기, 동화 같은 글 8 개를 더 확인했다.
- 주 실험(3.1~3.4)은 지시를 지켰는지만 문자열 규칙으로 판정했다. 글의 내용은 보강 실험(3.5, 3.9)에서 AI 심판과 단순 지표로만 점검했다.

# 2. 연구 방법

## 2.1 모델과 호출

주 실험(세트 1~3)의 응답은 Gemini API 의 gemini-3.5-flash-lite 로 만들었다(무료 등급). 호출마다 새 요청 하나에 프롬프트 한 개만 담았고 대화 기록은 없다. 온도 등 생성 설정은 지정하지 않고 API 기본값을 썼으며, 최대 출력 길이만 32,768 토큰으로 지정했다. 호출은 2026 년 10 월 12 일 16:10 부터 13 일 09:09 사이에 했다. 호출 사이에는 6 초 간격을 두었다. 응답은 실행 기록(run_sheet.txt)에 모델 이름, 시각과 함께 저장했다.

gpt-6-luna 는 OpenAI API(Responses API)로 호출했다. 이 모델은 ChatGPT 무료 서비스의 기본 모델이다(저자가 서비스 화면에서 확인). 호출은 Gemini 와 같은 방식(대화 기록 없는 단일 메시지, 생성 설정 기본값)이고 최대 출력 토큰만 32,000 으로 지정했다. 호출은 2026 년 10 월 16 일(보강 확인 실험), 18 일(주 실험), 20 일(지시 12 개 실험), 21~22 일(다른 예시 실험)에 했다.

## 2.2 과제

과제는 10 개이며 모두 한국어로 짧은 안내문을 쓰게 한다. 각 프롬프트는 상황 설명(과제 요청)과 지시 8 개로 이루어진다. 과제 요청은 표 1 과 같고, 전문은 재현 꾸러미의 conditions.json 에 있다.

**표 1. 과제 10 개**

| 과제 | 이름 | 요청 내용 |
|---|---|---|
| T01 | 이용약관 변경 안내 | 노트 서비스의 약관 변경 세 가지와 시행일, 탈퇴 기한을 알리는 안내문 |
| T02 | 회의 결과 공유 이메일 | 회의 메모(참석자, 확정 사항, 담당과 기한)를 팀원에게 공유하는 이메일 본문 |
| T03 | 배송 지연 사과 이메일 | 물류센터 점검으로 5 일 늦어진 배송을 사과하고 보상을 알리는 이메일 |
| T04 | 신제품 소개 | 보온 텀블러의 가격, 보온 시간, 무게, 색상을 알리는 소개 글 |
| T05 | 워크숍 안내 공지 | 일시, 장소, 준비물이 있는 사내 워크숍 공지 |
| T06 | 비밀번호 재설정 안내 | 재설정 링크의 유효 시간과 절차를 알리는 안내 |
| T07 | 신입 환영 글 | 신입 두 명의 합류와 환영 점심을 알리는 글 |
| T08 | 장애 보고서 | 서비스 장애의 시각, 원인, 조치를 정리한 보고 |
| T09 | 독서 모임 초대 문자 | 모임 일시와 참가비를 알리는 초대 문자 |
| T10 | 구독 환불 규정 안내 | 환불 가능 기간과 방법을 알리는 안내 |

## 2.3 기본 지시 8 개와 채점

모든 조건의 프롬프트에 같은 지시 8 개가 들어간다. 지시는 문자열 규칙으로 판정하며(표 2), 한 응답의 준수율은 지킨 지시 수를 8 로 나눈 값(%)이다. 이 값이 이 연구의 주된 지표인 기본 지시 준수율이다. 표 2 의 판정에서 문장은 마침표, 물음표, 느낌표로 끝나는 줄을 문장 단위로 나눠 센다.

**표 2. 기본 지시 8 개와 판정 방법**

| 번호 | 지시 | 판정 |
|---|---|---|
| 1 | 소제목은 '▶'로 시작하는 줄 정확히 4 줄 | '▶'로 시작하는 줄이 4 개 |
| 2 | 문단은 빈 줄로 나누어 정확히 4 개 | 문장이 있는 문단 덩어리가 4 개 |
| 3 | 첫 문단은 두 문장 | 첫 문단의 문장 수가 2 |
| 4 | 느낌표(!)는 전체에서 정확히 한 번 | 느낌표가 1 개 (핵심 지시) |
| 5 | 한 문단은 2 문장에서 4 문장 사이 | 모든 문단이 2~4 문장 |
| 6 | 전체 문장 수는 10 문장에서 14 문장 사이 | 전체 문장 수가 10~14 |
| 7 | 모든 문장은 '~요'로 끝나는 해요체 | 모든 문장이 '요'로 끝남 |
| 8 | 첫 문장은 공백 포함 20 자 이내 | 첫 문장이 20 자 이하 |

4 번 지시는 '핵심 지시'로, 맨 앞·맨 끝 조건에서 위치를 옮긴다.

## 2.4 실험 조건 9 개

기본 조건(C00)은 과제 요청 뒤에 지시 8 개를 한 문장으로 이어 붙인 프롬프트다. 나머지 아홉 조건은 기본 프롬프트에 요소 하나만 더하거나 구성을 바꾼다(표 3).

**표 3. 조건과 기본 프롬프트에 더한 것**

| 조건 | 이름 | 기본 프롬프트에서 달라지는 점 |
|---|---|---|
| C00 | 기본 | 과제 요청 + 지시 8 개(한 문장으로 연결). 기준 조건 |
| C01 | 형식 지정 | "맨 첫 줄에는 제목만 쓰고, 그 아래에 본문을 써 줘."를 덧붙임 |
| C02 | 번호 분할 | 과제 요청 뒤에 지시 8 개를 1~8 번 목록으로 나눠 씀 |
| C03 | 제약 명시 | "'정말'이라는 단어는 쓰지 말고, '확인'이라는 표현은 반드시 넣어 줘."를 덧붙임 |
| C04 | 예시 제시 | 지시 8 개를 모두 지킨 예시 글(도서관 이용 안내) 하나를 덧붙임. 모든 과제에 같은 예시 |
| C05 | 역할 부여 | 과제에 맞는 전문가 역할 한 문장을 맨 앞에 둠(예: 10 년차 인사팀 담당자) |
| C06 | 출력 길이 지정 | "전체 분량은 공백을 뺀 300 자에서 450 자 사이로 써 줘."를 덧붙임 |
| C07 | 핵심 지시 맨 앞 | 핵심 지시(느낌표 한 번)를 프롬프트 맨 앞으로 옮김 |
| C08 | 핵심 지시 맨 끝 | 핵심 지시를 프롬프트 맨 끝으로 옮김 |
| C09 | 자기 점검 요청 | "작성한 뒤 위 지시를 모두 지켰는지 스스로 확인하고, 고친 최종본만 출력해 줘."를 덧붙임 |

형식 지정, 제약 명시, 출력 길이 지정 조건은 기본 지시와 별개의 지시를 하나 더 준다 . 이 추가 지시를 지켰는지는 보조 지표로 따로 기록했다(제목 줄 규칙, '정말' 금지와 '확인' 포함, 300~450 자). 보조 지표는 순위에 반영하지 않는다.

## 2.5 실행 설계

세트 하나는 10 개 라운드로 이루어지고, 라운드 r 은 과제 Tr 하나를 쓴다. 한 라운드에서 열 조건이 모두 같은 과제에 대해 한 번씩 호출되므로 한 세트는 100 번 호출이다. 라운드 안의 조건 순서는 난수(시드 20, 21, 22)로 섞었다. 세트는 3 개이며 총 300 번이다. 모든 조건이 같은 과제 10 개를 세트마다 한 번씩 받으므로 조건당 30 회, 조건 사이 과제 구성은 같다.

모델 전환 안내가 뜬 호출은 제외하고 같은 과제·조건으로 다시 호출하기로 했으나, 이번 실험에서 제외된 호출은 없었다. 300 개 응답이 모두 유효했다. gpt-6-luna 는 같은 구조의 세트를 10 개(1,000 회, 난수 시드 141~150) 호출했고 3.6 절에서 분석한다.

## 2.6 통계 분석

같은 라운드의 조건들은 같은 과제를 받으므로, 조건과 기본의 비교는 (세트, 라운드) 단위 30 개의 짝 안에서 한다. 요소 하나의 효과는 짝마다 구한 준수율 차이(요소 - 기본)의 평균이다.

- 신뢰구간: 30 개 차이를 복원추출하는 부트스트랩(20,000 회, 시드 10)의 백분위 95% 구간.
- 검정: 차이의 부호를 무작위로 뒤집는 순열검정(20,000 회). 9 개 요소를 동시에 비교하므로 Holm 보정 p 값도 함께 보고한다.
- 순위: 기본 대비 차이가 큰 순서. 동률이면 같은 순위. 차이가 10%p 이하이면 '기본과 구분되지 않음'으로 표기한다(실험 전에 정한 실질적 차이 기준).

- 지시별 비교: 각 지시의 통과 횟수를 기본과 Fisher 정확검정으로 비교(30 회 대 30 회). 보정하지 않은 탐색용 값이다.

분석은 재현 꾸러미의 analyze.py 가 수행하며 시드가 고정되어 같은 값을 다시 얻는다.

### 2.7 예비 실험과 설계 확정 과정

기본 지시 준수율이 100%에 가깝거나 대부분 실패하면 요소 간 차이가 드러나지 않으므로, 기본 조건의 지시 준수율이 60~80% 안팎이 되도록 지시를 고르는 예비 실험을 했다. 조정 과정과 설계 변경(본 실험 A 에서 B 로의 교체 한 번, 이는 요소 조건의 결과를 본 뒤에 한 것이다)은 부록 D 의 표에 기록했다.

### 2.8 반복 및 보강 실험

주 실험을 마친 뒤 결과의 한계를 줄이려고 반복과 보강 실험을 했다. 설계, 분량, 판정 기준은 해당 데이터를 얻기 전에 꾸러미의 ext/README.md 에 적어 두었고, 분량은 결과와 상관없이 전부 수행해 모두 보고한다. 모두 대화 기록 없는 단일 메시지 호출이며, 한 세트는 과제 10 개를 한 번씩 쓰고 라운드마다 모든 조건이 같은 과제를 쓰는 주 실험과 같은 구조다.

- **주 실험 반복(R).** gemini-3.5-flash-lite 에서 주 실험과 같은 10 개 조건을 7 세트(세트 4~10, 700 회) 더 호출했다. 난수 시드만 다르다. 주 실험 세트 1~3 과 합친 10 세트(조건당 100 쌍)를 같은 통계 방식으로 분석한다. 3.1~3.4 절은 세트 1~3 으로 확정한 분석이고, 합산 결과는 3.5 절에 따로 보고한다.
- **예시 변형(V).** gemini-3.5-flash-lite 에서 기본(C00), 예시 1 개(C04), 예시 2 개(V2), 형식 틀(V3)을 비교했다. V2 는 C04 의 예시에 두 번째 예시(수영장 안내, 8 개 지시를 모두 지킨 글)를 더한 것이고, V3 는 '▶ (소제목) (문장). (문장).' 꼴의 내용 없는 틀이다. 세트 12 개(120 쌍), 480 회이며 주 실험과 같은 짝지음·통계 방식을 썼다. 예시 1 개와의 직접 비교도 했다.
- **다른 모델 반복(M).** gemini-3.1-flash-lite 에서 기본과 예시 제시 두 조건을 10 세트(100 쌍) 호출했다.
- **OpenAI 모델(G).** OpenAI API(Responses API)로 gpt-6-luna 를 20 세트(200 쌍, 400 회), gpt-5.6-luna 를 30 세트(300 쌍, 600 회) 호출했고, 두 모델 모두 기본과 예시 제시 두 조건만 비교했다. 두 모델은 섞지 않고 따로 분석한다. ChatGPT 무료 서비스의 기본 모델이 실험 중에 gpt-5.6-luna 에서 gpt-6-luna 로 바뀐 것을 확인해, gpt-6-luna 를 주 모델의 하나로, gpt-5.6-luna 를 비교 결과로 정했다. 추론 강도 등 다른 설정은 기본값으로 두고 최대 출력 토큰만 32,000 으로 지정했다. 일반 대화 서비스는 API 와 다른 시스템 지시문을 붙일 수 있어 같은 결과가 나온다고 보장되지 않는다.
- **gpt-6-luna 아홉 요소(R_gpt6).** 주 모델의 하나인 gpt-6-luna 에서 주 실험과 같은 10 개 조건을 10 세트(조건당 100 쌍, 1,000 회) 호출했다. 프롬프트와 지시는 주 실험과 똑같이 두었고 이 모델에 맞춰 조정하지 않았다. 통계 방식(짝지은 차이, 부트스트랩 구간, 순열검정, Holm 보정, 10%p 기준)도 같다.
- **예시가 지시와 어긋날 때(X).** 기본(C00), 정상 예시(C04), 중립 안내를 붙인 정상 예시(N0), 구조가 어긋난 예시(X1: 소제목과 문단이 5 개라 지시 1·2 와 어긋남), 문체가 어긋난 예시(X2: 합니다체라 지시 7 과 어긋남)를 모델마다 10 세트(100 쌍, 500 회) 비교했다. N0, X1, X2 는 같은 중립 안내문("예시(내용은 다른 글이야):")을 쓰고, X1·X2 의 예시는 충돌하는 지시만 어기고 나머지 지시는 지킨 글이다. 충돌 지시의 통과율을 N0 와 비교해 판정하며, 차이의 구간 상한이 0 미만이고 -

10%p 이하이면 '예시 우선', -10%p 보다 크면 '지시 우선', 그 밖은 '혼합'으로 보기로 미리 정했다. 예시를 그대로 따라 쓴 응답 비율과 충돌하지 않는 나머지 지시의 통과율도 보조로 잰다.

- **다른 글 종류(S).** 안내문이 아닌 글 8 개(뉴스 요약문, 과학 개념 설명글, 북토크 후기, 설득하는 글, 하루 일기, 동아리 지원 동기, 발표 원고, 짧은 동화)로 기본과 예시 제시 두 조건을 비교했다. 지시 8 개와 예시(도서관 이용 안내)는 주 실험과 같다. gemini-3.5-flash-lite 는 10 세트(80 쌍, 160 회), gpt-6-luna 는 20 세트(160 쌍, 320 회)이며, 과제와 분량은 결과를 보기 전에 정했다.
- **예시의 길이·내용 통제(L).** gemini-3.5-flash-lite 에서 기본(C00), 예시 제시(C04), L1, L2 를 10 세트(조건당 100 쌍, 400 회) 비교했다. L1 은 예시와 같은 내용·같은 문체(해요체)이지만 소제목과 문단 구분이 없는 줄글(233 자, 느낌표 1 회 포함), L2 는 길이가 비슷하고(239 자) 주제와 문체(합니다체)가 다른 사계절 설명글이다. 둘 다 '참고 글:'이라는 안내만 붙였고 지시를 지켰다는 설명은 붙이지 않았다. 통제 조건과 예시 제시의 차이 구간 상한이 0 미만이고 -10%p 이하이면 '예시가 더 높음', 통제 조건이 기본보다 10%p 보다 크게 높고 구간 하한이 0 초과이면 '통제 글도 효과', 그 밖은 '혼합'으로 보기로 결과를 보기 전에 정했다.
- **지시 12 개(D).** gpt-6-luna 에서 지시를 8 개에서 12 개로 늘린 과제를 만들어 주 실험과 같은 10 개 조건을 8 세트(조건당 64 쌍, 640 회) 호출했다. 글 종류는 안내문이 아닌 글 8 종(S 와 같다, 번호만 T21~T28)이고, 추가한 4 개는 물음표 정확히 1 회, '그리고'·'그래서'·'또한' 쓰지 않기, 모든 문장 공백 포함 40 자 이내, 문장 끝 두 글자가 같은 문장 3 번 연속 쓰지 않기다. 예시 제시의 예시는 12 개 지시를 모두 지키도록 다시 썼고 생성 시 자동으로 확인한다. 분량과 통계 방식(짝지은 차이, 부트스트랩, 순열검정, Holm 보정, 10%p 기준)은 결과를 보기 전에 정했다.
- **다른 예시(E).** 기본(C00), 도서관 예시(C04), 주제와 문장 구성이 다른 예시 두 개를 gemini-3.5-flash-lite 와 gpt-6-luna 에서 각각 10 세트(조건당 100 쌍, 모델마다 400 회) 비교했다. E1 은 헌 옷 수거 안내(12 문장), E2 는 분리배출 안내(10 문장, 도서관 예시와 같은 문장 구성)이고 둘 다 8 개 지시를 모두 지킨 글이며 같은 안내문('예시(내용은 다르지만 위 지시를 모두 지킨 글이야):')을 썼다. 기본 대비 차이가 10%p 초과이고 구간 하한이 0 초과이면 '효과 유지', 그 밖은 '효과 불분명'으로 보기로 결과를 보기 전에 정했다.
- **사실 점검(F).** 응답을 만든 회사와 다른 회사의 모델이 판정하도록 했다. gemini-3.5-flash-lite 응답(10 세트의 기본·예시 제시 200 개)은 gpt-6-luna 가, gpt-6-luna 응답(보강 확인 실험 세트 1~10 의 200 개)은 gemini-3.5-flash-lite 가 판정했다. 심판에게 과제 문장에서 뽑은 사실 목록(과제당 4~9 개)과 응답을 주고 각 사실이 정확히 들어 있는지, 요청에 없는 구체적 숫자·이름을 지어냈는지(지어낸 사실 수), 어조와 자연스러움(1~5)을 JSON 으로 답하게 했다. 형식 규칙은 평가하지 않도록 했다. 사실 보존율 차이의 구간 상한이 0 미만이면 '예시가 사실 보존을 낮춤'으로 보기로 미리 정했다.
- **내용 질(Q).** 주 실험의 기본·예시 제시 응답을 같은 과제끼리 짝지어(30 짝) gemma-4-26b-a4b-it 에게 '형식 규칙은 무시하고 요청한 사실을 빠짐없이 정확히 전하고 읽기 자연스러운 글'을 고르게 했다. A/B 위치를 바꿔 짝마다 2 번(총 60 회) 물었다. 사전에 정한 기준은 예시 조건의 승률 구간 상한이 50% 미만이면 '내용 질을 낮춤'으로 보는 것이다. 호출 없이 계산한 지표로 예시 글과 겹치는 6 글자 조각의 비율을 잰다.

내용 보존 점검(사실 보존율, 응답 길이)은 심판 결과를 본 뒤에 추가한 사후 분석이다. 과제 문장에 있던 숫자와 단위, 따옴표 이름이 응답에 그대로 들어 있는 비율을 센다. Q 와 내용 보존 점검은 주 실험의 gemini-3.5-flash-lite 응답(30 쌍)에만 했고, 사실 점검(F)은 두 주 모델의 응답에 했다.

### 2.9 AI 활용 고지

응답 생성에는 Gemini API 와 OpenAI API 를 썼고, 내용 판정의 심판으로 gemma-4-26b-a4b-it, gpt-6-luna, gemini-3.5-flash-lite 를 썼다. 실험 설계 논의, 채점·분석 스크립트 작성, 원고 초안 작성에는 Claude(Anthropic)를 보조로 썼다. 연구 질문과 가설, 실험 설계의 방향, 보강 실험의 범위, 주 모델의 선정은 저자가 정했다.

## 3. 결과

3.1~3.4 절은 gemini-3.5-flash-lite 의 처음 3 세트(300 회)로 확정한 분석이고, 3.5 절은 그 반복과 보강 실험, 3.6 절 이후는 gpt-6-luna 와 추가 실험의 결과다.

### 3.1 요소별 순위

300 번 호출이 모두 유효했다. 기본 조건의 지시 준수율은 73.3%(세트별 77.5, 71.2, 71.2%)였다. 표 4 와 그림 1 이 요소별 결과다.

**표 4. 요소별 기본 지시 준수율과 기본 대비 차이 (조건당 30 회)**

| 순위 | 조건 | 준수율 (%) | 기본 대비 (%p) | 95% 구간 | 순열 p | Holm p | 개선/악화/동률 | 10%p 기준 |
|---|---|---|---|---|---|---|---|---|
| 기준 | 기본 | 73.3 | | | | | | |
| 1 | 예시 제시 | 90.0 | +16.7 | [+11.7, +22.5] | <0.001 | <0.001 | 22/0/8 | 구분됨 |
| 2 | 제약 명시 | 75.0 | +1.7 | [-4.2, +7.5] | 0.687 | 1.000 | 10/8/12 | 구분 안 됨 |
| 3 | 번호 분할 | 74.6 | +1.2 | [-6.2, +9.2] | 0.833 | 1.000 | 13/12/5 | 구분 안 됨 |
| 4 | 출력 길이 지정 | 74.2 | +0.8 | [-4.6, +6.2] | 0.880 | 1.000 | 9/9/12 | 구분 안 됨 |
| 5 | 자기 점검 요청 | 72.5 | -0.8 | [-6.7, +4.6] | 0.888 | 1.000 | 12/10/8 | 구분 안 됨 |
| 6 | 핵심 지시 맨 앞 | 72.1 | -1.2 | [-9.6, +7.1] | 0.845 | 1.000 | 9/11/10 | 구분 안 됨 |
| 7 | 핵심 지시 맨 끝 | 68.3 | -5.0 | [-10.8, +0.8] | 0.144 | 0.863 | 5/13/12 | 구분 안 됨 |
| 8 | 역할 부여 | 65.4 | -7.9 | [-15.4, -0.4] | 0.068 | 0.479 | 7/16/7 | 구분 안 됨 |
| 9 | 형식 지정 | 63.8 | -9.6 | [-16.7, -2.5] | 0.016 | 0.128 | 5/16/9 | 구분 안 됨 |

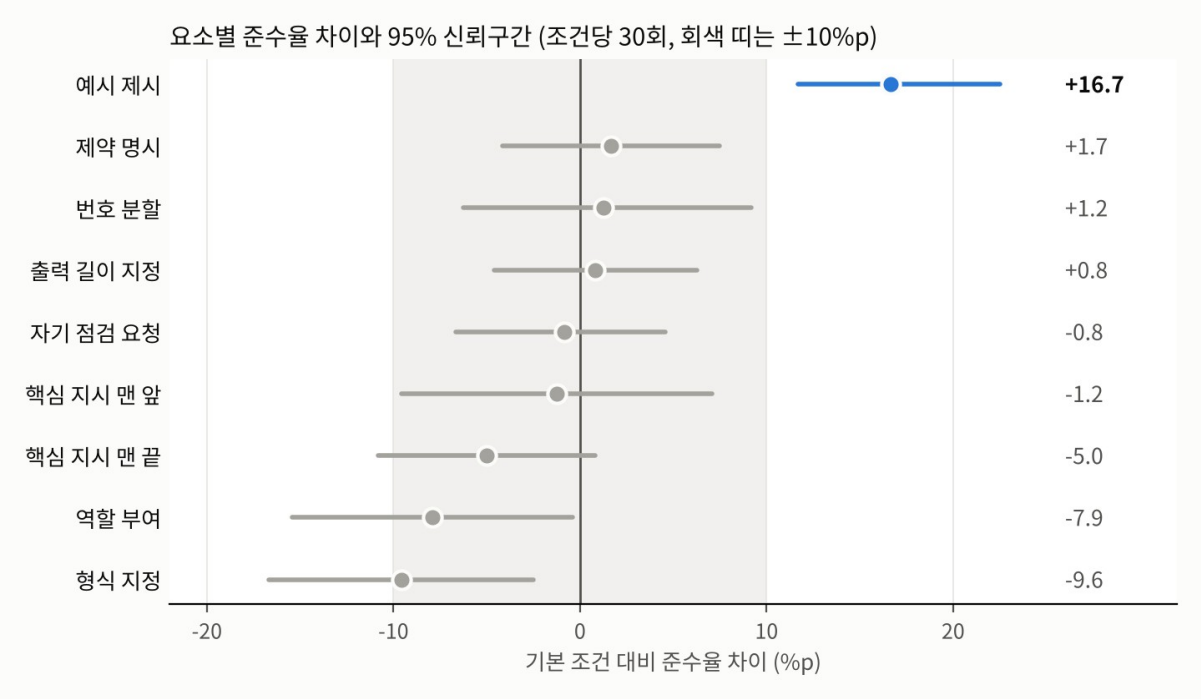



그림 1. 기본 대비 준수율 차이와 95% 신뢰구간. 파란색은 Holm 보정 후에도 유의한 조건, 회색 띠는 ±10%p.

**예시 제시만 기본보다 뚜렷하게 높았다.** 90.0%로 기본보다 16.7%p 높았고(95% 구간 +11.7~+22.5, Holm 보정 p<0.001), 30 개 짝 중 22 개에서 개선, 8 개에서 동률, 악화는 0 개였다. 10%p 기준으로도 유일하게 '구분됨'이다. 나머지 여덟 요소는 모두 기본과의 차이가 10%p 이하였다.

형식 지정(-9.6%p, 구간 -16.7~-2.5, 순열 p=0.016)과 역할 부여(-7.9%p, 구간 -15.4~-0.4, p=0.068)는 낮아지는 쪽이었다. 두 구간은 0 을 포함하지 않지만 9 개를 동시에 비교하므로 Holm 보정 후에는 각각 p=0.128, 0.479 로 유의하지 않다. 위 구간은 다중비교를 보정하지 않은 값이다. 번호 분할, 제약 명시, 출력 길이 지정, 자기 점검 요청, 핵심 지시의 위치(맨 앞·맨 끝)는 기본과 구분되지 않았다.

### 3.2 예시 제시 효과의 일관성

예시 제시의 개선은 한 세트나 한 과제에 몰려 있지 않았다. 세 세트에서 기본 대비 90.0 대 77.5%, 92.5 대 71.2%, 87.5 대 71.2%였고, 열 개 과제 모두에서 기본보다 높았다(표 5).

**표 5. 과제별 기본 지시 준수율: 기본과 예시 제시 (%, 과제당 3 회)**

| 과제 | 이름 | 기본 | 예시 제시 | 차이(%p) |
|---|---|---|---|---|
| T01 | 이용약관 변경 안내 | 79 | 92 | +13 |
| T02 | 회의 결과 공유 이메일 | 79 | 83 | +4 |
| T03 | 배송 지연 사과 이메일 | 50 | 88 | +38 |
| T04 | 신제품 소개 | 75 | 92 | +17 |
| T05 | 워크숍 안내 공지 | 83 | 96 | +13 |
| T06 | 비밀번호 재설정 안내 | 79 | 96 | +17 |
| T07 | 신입 환영 글 | 54 | 83 | +29 |
| T08 | 장애 보고서 | 79 | 92 | +13 |
| T09 | 독서 모임 초대 문자 | 79 | 92 | +13 |

| 과제 | 이름 | 기본 | 예시 제시 | 차이(%p) |
|---|---|---|---|---|
| T10 | 구독 환불 규정 안내 | 75 | 88 | +13 |

기본에서 가장 낮았던 두 과제(T03 50%, T07 54%)에서 개선이 가장 컸다.

### 3.3 지시별 분해

그림 2 는 조건별, 지시별 통과율이다. 기본 조건의 지시별 통과율은 소제목 4 줄 57%, 문단 4 개 50%, 첫 문단 2 문장 80%, 느낌표 한 번 87%, 문단당 2~4 문장 80%, 전체 10~14 문장 70%, 해요체 77%, 첫 문장 20 자 이내 87%로, 이번 설계에서는 항상 지키거나 항상 어기는 지시가 없었다.

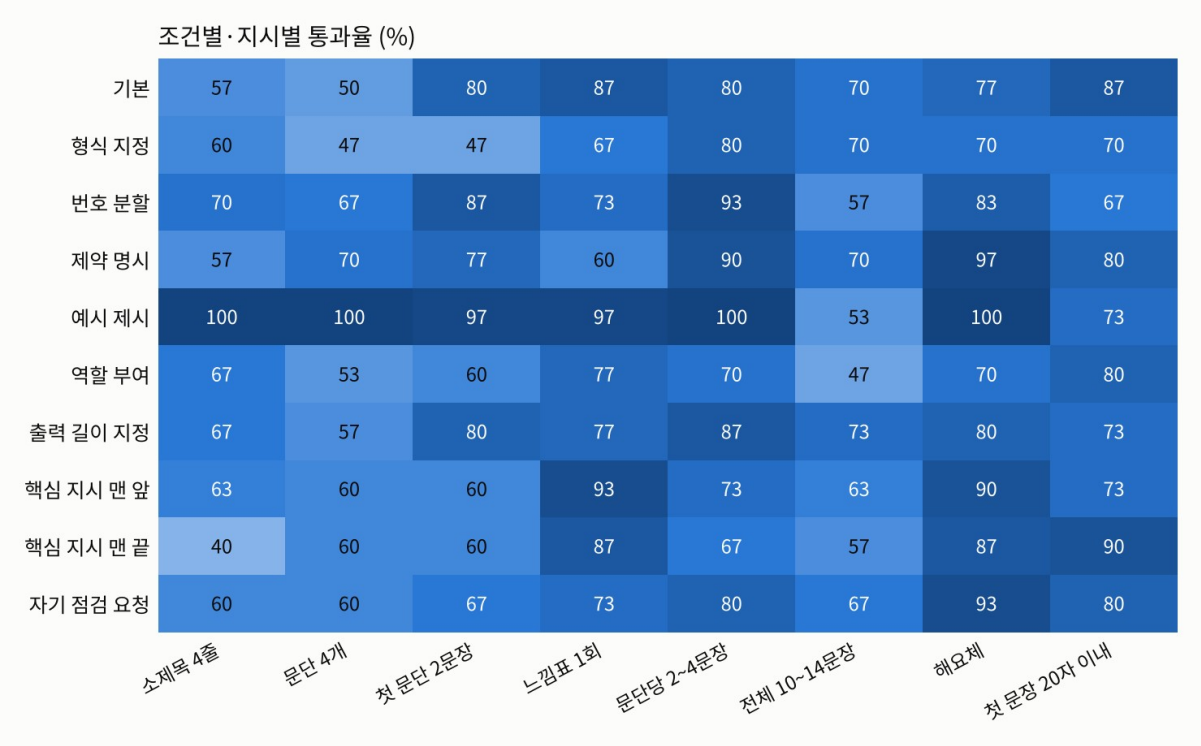



그림 2. 조건별·지시별 통과율(%). 각 칸은 30 회 중 통과 비율.

예시 제시는 소제목 4 줄(57→100%), 문단 4 개(50→100%), 문단당 2~4 문장(80→100%), 해요체(77→100%)를 거의 모두 지키게 했다(Fisher 정확검정, 보정 전 $p<0.05$). 반면 전체 문장 수 10~14 는 70%에서 53%로 낮아졌고(유의하지 않음), 첫 문장 20 자 이내도 87%에서 73%로 내려갔다(유의하지 않음). 이 밖에 보정 전 기준으로 달라진 지시는 두 가지다. 형식 지정에서 첫 문단 2 문장이 80%에서 47%로 낮아졌고($p=0.015$), 제약 명시에서 느낌표 한 번이 87%에서 60%로 낮아졌다($p=0.039$). 다중비교를 보정하면 이 둘은 우연과 구분되지 않는다.

### 3.4 보조 지표: 추가 지시와 출력 길이

추가 지시를 따로 준 세 조건의 추가 지시 준수율은 제약 명시 100%('정말' 금지와 '확인' 포함), 형식 지정 83%(제목 줄), 출력 길이 지정 40%(300~450 자)였다. 길이를 숫자로 지정해도 60%의 응답은 그 범위를 벗어났다.

조건별 평균 출력 길이(공백 제외 글자 수)는 기본 282 자, 예시 제시 217 자, 핵심 지시 맨 앞 248 자, 형식 지정 320 자였다. 평균 문장 수는 기본 11.1 문장, 예시 제시 9.7 문장이었다.

### 3.5 반복 및 보강 실험

**주 실험 반복(10 세트 합산).** 세트 4~10(700 회)을 더해 10 세트(조건당 100 쌍)로 분석한 결과가 표 6 이다. 기본 조건의 지시 준수율은 69.5%였고, 예시 제시는 87.9%로 +18.4%p(구간 +15.0~+21.8, Holm p<0.001)였다. 반복 7 세트만 보면(70 쌍) 기본 67.9%, 예시 제시 87.0%로 +19.1%p(구간 +14.8~+23.2)여서 처음 3 세트의 결과(+16.7%p)와 같은 방향이다. 나머지 여덟 요소는 합산에서도 기본과의 차이가 10%p 이하였다. 처음 30 쌍에서 낮은 쪽으로 보였던 형식 지정(-9.6%p)과 역할 부여(-7.9%p)는 합산에서 -5.5%p(구간 -9.9~-1.2, 보정 전 p=0.015, Holm p=0.108), -4.8%p(구간 -8.1~-1.4, 보정 전 p=0.010, Holm p=0.078)로 작아졌다. 구간이 0 을 포함하지 않지만 보정 후에는 유의하지 않으며, 반복 7 세트만 보면 -3.8%p(구간 -9.1~+1.4), -3.4%p(구간 -7.0~+0.2)로 구간이 0 을 포함한다. 처음 30 쌍에서 나온 큰 감소의 일부는 우연이었을 가능성이 있다. 지시별 통과 횟수는 부록 B 에 있다.

**표 6. 주 실험 반복을 합친 요소별 결과 (gemini-3.5-flash-lite, 10 세트, 조건당 100 쌍)**

| 조건 | 이름 | 준수율(%) | 기본 대비 (%p) | 95% 구간 | 순열 p | Holm p | 10%p 기준 |
|---|---|---|---|---|---|---|---|
| C00 | 기본 | 69.5 | 기준 | | | | |
| C01 | 형식 지정 | 64.0 | -5.5 | -9.9 ~ -1.2 | 0.015 | 0.108 | 구분 안 됨 |
| C02 | 번호 분할 | 71.5 | +2.0 | -2.1 ~ +6.1 | 0.379 | 1.000 | 구분 안 됨 |
| C03 | 제약 명시 | 72.1 | +2.6 | -0.9 ~ +6.1 | 0.165 | 0.987 | 구분 안 됨 |
| C04 | 예시 1 개 | 87.9 | +18.4 | +15.0 ~ +21.8 | <0.001 | <0.001 | 구분됨 |
| C05 | 역할 부여 | 64.8 | -4.8 | -8.1 ~ -1.4 | 0.010 | 0.078 | 구분 안 됨 |
| C06 | 출력 길이 지정 | 70.1 | +0.6 | -2.5 ~ +3.8 | 0.761 | 1.000 | 구분 안 됨 |
| C07 | 핵심 지시 맨 앞 | 70.6 | +1.1 | -3.0 ~ +5.1 | 0.637 | 1.000 | 구분 안 됨 |
| C08 | 핵심 지시 맨 끝 | 68.2 | -1.2 | -5.0 ~ +2.5 | 0.558 | 1.000 | 구분 안 됨 |
| C09 | 자기 점검 요청 | 68.8 | -0.8 | -4.0 ~ +2.5 | 0.719 | 1.000 | 구분 안 됨 |

**예시 변형.** 같은 모델에서 세 요소 모두 기본보다 뚜렷하게 높았다(표 7). 예시 1 개 +21.6%p, 예시 2 개 +22.5%p, 형식 틀 +20.2%p 였고 모두 Holm 보정 후 p<0.001 이다. 예시 1 개와 직접 비교하면 예시 2 개는 +0.9%p(구간 -1.2~+3.1), 형식 틀은 -1.4%p(구간 -3.6~+0.9)로 차이를 찾지 못했다. 이 보강 실험에서 기본 조건의 준수율은 67.3%로 주 실험(73.3%)과 합산(69.5%)과 비슷했고, 예시 1 개의 효과는 +21.6%p 로 같은 방향이었다.

**표 7. 예시 변형 비교 (gemini-3.5-flash-lite, 120 쌍, 조건당 120 회)**

| 조건 | 이름 | 준수율(%) | 기본 대비(%p) | 95% 구간 | Holm p | 10%p 기준 |
|---|---|---|---|---|---|---|
| C00 | 기본 | 67.3 | 기준 | | | |
| C04 | 예시 1 개 | 88.9 | +21.6 | +18.1 ~ +25.1 | <0.001 | 구분됨 |
| V2 | 예시 2 개 | 89.8 | +22.5 | +18.8 ~ +26.4 | <0.001 | 구분됨 |
| V3 | 형식 틀 | 87.5 | +20.2 | +16.5 ~ +24.0 | <0.001 | 구분됨 |

지시별로 보면 세 요소가 같은 지시를 같은 방향으로 올린 것은 아니다(표 8). 소제목 4 줄과 문단 4 개는 세 조건 모두 98~100%였다. 전체 10~14 문장 지시는 기본 68%였고 예시 1 개에서 53%, 예시 2 개에서 39%

로 낮아졌으며 형식 틀에서는 83%로 높아졌다. 첫 문장 20 자 이내는 기본 83%에서 예시 1 개 73%, 형식 틀 59%로 낮아졌고 예시 2 개에서는 90%로 높아졌다. 예시를 그대로 따라 쓰면 응답의 문장 수와 첫 문장 길이가 지시 범위를 벗어나기 쉬웠고, 문장 수가 드러나는 틀에서는 문장 수 지시가 더 잘 지켜졌다고 해석할 수 있다. 이는 해석이다.

**표 8. 예시 변형의 지시별 통과 비율 (120 회 중)**

| 조건 | 이름 | 소제목 4 줄 | 문단 4 개 | 첫 문단 2 문장 | 느낌표 1 회 | 문단당 2~4 문장 | 전체 10~14 문장 | 해요체 | 첫 문장 20 자 |
|---|---|---|---|---|---|---|---|---|---|
| C00 | 기본 | 43% | 49% | 68% | 67% | 73% | 68% | 88% | 83% |
| C04 | 예시 1 개 | 100% | 100% | 97% | 89% | 99% | 53% | 100% | 73% |
| V2 | 예시 2 개 | 100% | 100% | 94% | 98% | 98% | 39% | 100% | 90% |
| V3 | 형식 틀 | 99% | 98% | 94% | 73% | 100% | 83% | 93% | 59% |

**다른 모델.** gemini-3.1-flash-lite 의 100 쌍에서 기본 80.4%, 예시 제시 92.9%로 +12.5%p(구간 +9.8~+15.4, 순열검정 p<0.001)였다. 방향은 주 실험과 같고 크기는 조금 작았다. 지시별로는 소제목 4 줄(87%→100%), 문단 4 개(55%→100%), 전체 10~14 문장(61%→100%)이 크게 올랐지만 첫 문장 20 자 이내는 83%에서 59%로 낮아졌다. 주 실험에서도 이 지시가 낮아지는 경향이었다.

**GPT.** gpt-6-luna 의 200 쌍에서 기본 96.2%, 예시 제시 97.9%로 +1.7%p(구간 +0.4~+3.1, Holm p=0.020)였다. 네 모델의 비교는 표 9 에 있다. 기본이 이미 96.2%라 올라갈 여지가 3.8%p 뿐이었다. gpt-5.6-luna 의 300 쌍에서는 기본 91.0%, 예시 제시 97.3%로 +6.3%p(구간 +4.3~+8.5, Holm p<0.001)였다. 두 모델 모두 예시 제시가 높았지만 10%p 기준으로는 기본과 구분되지 않는다. 지시별로 gpt-5.6-luna 는 첫 문단 2 문장(80%→96%), 첫 문장 20 자 이내(90%→100%), 문단당 2~4 문장(88%→96%), 전체 10~14 문장(85%→94%)이 올랐고, gpt-6-luna 는 첫 문단 2 문장(93%→97%), 전체 10~14 문장(90%→94%), 문단당 2~4 문장(95%→97%), 첫 문장 20 자 이내(97%→100%)가 올랐다. 해요체는 두 모델에서 거의 그대로였다(gpt-5.6-luna 91%→94%, gpt-6-luna 97%→96%). 두 모델 모두 기본 등급의 소형 모델이며 널리 쓰이는 대형 모델에서의 결과는 아니다.

**표 9. 모델별 예시 제시 효과 (기본 대비)**

| 모델 | 쌍 | 기본(%) | 예시 제시 (%) | 차이(%p) | 95% 구간 | Holm p |
|---|---|---|---|---|---|---|
| gemini-3.5-flash-lite (10 세트) | 100 | 69.5 | 87.9 | +18.4 | +15.0 ~ +21.8 | <0.001 |
| gemini-3.1-flash-lite | 100 | 80.4 | 92.9 | +12.5 | +9.8 ~ +15.4 | <0.001 |
| gpt-5.6-luna | 300 | 91.0 | 97.3 | +6.3 | +4.3 ~ +8.5 | <0.001 |
| gpt-6-luna (보강 확인, 20 세트) | 200 | 96.2 | 97.9 | +1.7 | +0.4 ~ +3.1 | 0.020 |
| gpt-6-luna (주 모델 실험, 10 세트) | 100 | 96.9 | 98.9 | +2.0 | +0.0 ~ +4.2 | 0.571 |

gemini-3.5-flash-lite(10 세트)와 gpt-6-luna(주 모델 실험)의 Holm p 는 아홉 요소를 함께 비교한 보정값이고, 나머지는 기본과 예시 제시 두 조건만 비교한 값이다.

**내용 질.** AI 심판 60 회 중 예시 제시가 이긴 비율은 짝 단위로 16.7%(95% 구간 6.7~28.3%)였다. 구간 상한이 50% 미만이므로 사전에 정한 기준으로는 '예시가 내용 질을 낮춤'이다. A 자리 선택은 60 회 중 32

회로 위치 편향은 크지 않았다. 예시와 겹치는 6 글자 조각은 기본 0.04%, 예시 제시 0.21%로 예시를 거의 베끼지 않았다.

이 결과가 응답 길이와 얽혀 있는지 보려고 사후 점검을 했다(표 10). 예시 제시의 응답은 기본보다 평균 약 66 자(23%) 짧았고, 과제 문장 속 사실을 담은 비율이 95.0%에서 87.8%로 낮아졌다(차이 -7.1%p, 구간 -15.3~-1.2). 심판이 선호한 것은 더 길고 사실을 더 많이 담은 쪽이었을 가능성이 크다. 다만 한 개의 작은 심판 모델의 판단이고, 사실 보존율도 숫자·이름 일치만 세는 단순한 지표라 정확한 측정은 아니다.

**표 10. 내용 보존 점검 (주 실험 응답, 30 쌍, 사후 분석)**

| 지표 | 기본 | 예시 제시 | 차이 | 95% 구간 |
|---|---|---|---|---|
| 사실 보존율(%) | 95.0 | 87.8 | -7.1 | -15.3 ~ -1.2 |
| 응답 길이(공백 제외 글자) | 282.4 | 216.7 | -65.7 | -89.0 ~ -42.9 |

### 3.6 gpt-6-luna 의 아홉 요소 비교

gpt-6-luna 에서 주 실험과 같은 10 개 조건을 10 세트(조건당 100 쌍) 호출한 결과가 표 11 이다. 기본 조건의 지시 준수율이 96.9%로 이미 높아 올라갈 여지가 3.1%p 뿐이었고, 아홉 요소 모두 기본과의 차이가 10%p 이하였다. 가장 높은 것은 예시 제시(+2.0%p, 구간 +0.0~+4.2, 보정 전 p=0.086)였고 가장 낮은 것은 핵심 지시 맨 앞(-2.5%p, 구간 -5.0~-0.1, 보정 전 p=0.062)이었다. Holm 보정 후에는 어느 조건도 유의하지 않았다(p≥0.557).

**표 11. gpt-6-luna 의 요소별 결과 (10 세트, 조건당 100 쌍)**

| 조건 | 이름 | 준수율(%) | 기본 대비 (%p) | 95% 구간 | 순열 p | Holm p | 10%p 기준 |
|---|---|---|---|---|---|---|---|
| C00 | 기본 | 96.9 | 기준 | | | | |
| C01 | 형식 지정 | 94.0 | -2.9 | -6.0 ~ +0.0 | 0.076 | 0.571 | 구분 안 됨 |
| C02 | 번호 분할 | 96.0 | -0.9 | -2.6 ~ +1.0 | 0.426 | 1.000 | 구분 안 됨 |
| C03 | 제약 명시 | 95.0 | -1.9 | -3.9 ~ +0.0 | 0.071 | 0.571 | 구분 안 됨 |
| C04 | 예시 1 개 | 98.9 | +2.0 | +0.0 ~ +4.2 | 0.086 | 0.571 | 구분 안 됨 |
| C05 | 역할 부여 | 96.0 | -0.9 | -3.1 ~ +1.2 | 0.524 | 1.000 | 구분 안 됨 |
| C06 | 출력 길이 지정 | 97.4 | +0.5 | -1.9 ~ +2.9 | 0.766 | 1.000 | 구분 안 됨 |
| C07 | 핵심 지시 맨 앞 | 94.4 | -2.5 | -5.0 ~ -0.1 | 0.062 | 0.557 | 구분 안 됨 |
| C08 | 핵심 지시 맨 끝 | 98.4 | +1.5 | -0.8 ~ +3.9 | 0.270 | 1.000 | 구분 안 됨 |
| C09 | 자기 점검 요청 | 96.4 | -0.5 | -3.1 ~ +2.0 | 0.778 | 1.000 | 구분 안 됨 |

지시별로 보면(부록 B3) 기본 조건에서 낮았던 것은 첫 문단 2 문장(90%), 해요체(94%), 전체 10~14 문장(96%)이었다. 예시 제시는 첫 문단 2 문장을 100%, 해요체를 99%로 올렸지만 전체 10~14 문장은 92%로 낮아졌다. 이는 gemini-3.5-flash-lite 에서 보인 패턴과 같다. 같은 지시를 gemini-3.5-flash-lite 는 기본에서 69.5%만 지켰으므로, 두 모델의 차이는 모델 능력과 함께 지시의 난이도를 gemini-3.5-flash-lite 의 기본 조건에 맞춰 골랐다는 설계(부록 D)가 만든 것이다. 따라서 이 결과는 'gpt-6-luna 에서는 요소가 효과가 없다'가 아니라 '이 지시와 과제에서는 요소의 효과를 가려낼 여지가 작았다'로 읽어야 한다.

### 3.7 예시가 지시와 어긋날 때

예시와 지시가 어긋나는 조건을 따로 만들어 확인했다(표 12). gemini-3.5-flash-lite 에서 구조가 어긋난 예시(소제목·문단 5 개)를 주어도 소제목 4 줄·문단 4 개 지시의 통과율은 99.0%로 정상 예시(99.5%)와 같았고(차이 -0.5%p, 구간 -3.0~+1.5), 예시를 그대로 따라 쓴 응답은 1.0%였다. 이 모델은 개수를 말로 지정한 지시가 예시와 충돌하면 지시를 따랐다. 반면 합니다체 예시에서는 해요체 지시 통과율이 정상 예시의 97.0%에서 74.0%로 떨어졌다(차이 -23.0%p, 구간 -32.0~-14.0). 기본 조건(87.0%)보다도 13%p 낮다(구간 -23.0~-3.0). 합니다체 문장을 그대로 베낀 응답은 5.0%뿐이어서 예시를 통째로 베꼈다기보다 문체의 영향을 받은 것으로 보인다. 충돌하지 않는 나머지 지시의 통과율에는 영향이 없었다(차이 -0.7%p, -1.3%p, 구간은 모두 0 포함). gpt-6-luna 는 두 경우 모두 충돌 지시의 통과율이 정상 예시와 같거나 높아(차이 +0.0%p, +2.0%p) 지시를 따랐고 예시를 따라 쓴 응답은 없었다.

**표 12. 예시가 지시와 어긋날 때 충돌 지시의 통과율 (모델마다 100 쌍)**

| 모델 | 충돌 지시 | 기본 (%) | 정상 예시 | 중립 안내 | 어긋난 예시 | 어긋난 예시 - 중립 안내(%p) | 판정 |
|---|---|---|---|---|---|---|---|
| gemini-3.5-flash-lite | 구조 어긋남(소제목·문단 5 개) | 48.0 | 100.0 | 99.5 | 99.0 | -0.5 [-3.0, +1.5] | 지시 우선 |
| gemini-3.5-flash-lite | 문체 어긋남(합니다체) | 87.0 | 100.0 | 97.0 | 74.0 | -23.0 [-32.0, -14.0] | 예시 우선 |
| gpt-6-luna | 구조 어긋남(소제목·문단 5 개) | 99.5 | 100.0 | 100.0 | 100.0 | +0.0 [+0.0, +0.0] | 지시 우선 |
| gpt-6-luna | 문체 어긋남(합니다체) | 95.0 | 97.0 | 95.0 | 97.0 | +2.0 [-3.0, +7.0] | 지시 우선 |

### 3.8 안내문이 아닌 글

안내문이 아닌 글 8 종에서도 방향은 같았다(표 13). gemini-3.5-flash-lite 는 기본 59.8%에서 예시 제시 75.8%로 +15.9%p(구간 +12.0~+20.0, 80 쌍)였고 10%p 기준으로도 구분됐다. 기본 준수율이 주 실험(69.5%)보다 낮은 것은 이 글 종류에서 같은 지시를 지키기가 더 어렵다는 뜻이다. 과제별로는 8 개 중 7 개에서 올랐고 짧은 동화에서는 차이가 없었다(표 14, 과제당 10 쌍이라 탐색용이다). 지시별로는 소제목 4 줄(55/80→80/80), 문단 4 개(57/80→80/80), 첫 문단 2 문장(27/80→69/80), 문단당 2~4 문장(59/80→77/80), 해요체(57/80→73/80)가 올랐고 전체 10~14 문장은 42/80 에서 19/80 로 낮아졌다. 주 실험과 같은 패턴이다. gpt-6-luna 는 97.8%에서 99.2%로 +1.4%p(구간 +0.3~+2.6, 160 쌍)였고 10%p 기준에서는 구분되지 않는다.

**표 13. 안내문이 아닌 글 8 종의 결과 (기본과 예시 제시)**

| 모델 | 쌍 | 기본(%) | 예시 제시 (%) | 차이(%p) | 95% 구간 | 10%p 기준 |
|---|---|---|---|---|---|---|
| gemini-3.5-flash-lite (10 세트) | 80 | 59.8 | 75.8 | +15.9 | +12.0 ~ +20.0 | 구분됨 |
| gpt-6-luna (20 세트) | 160 | 97.8 | 99.2 | +1.4 | +0.3 ~ +2.6 | 구분 안 됨 |

**표 14. 과제별 기본 지시 준수율: 기본과 예시 제시 (%, 탐색용)**

| 과제 | 이름 | Gem. 기본 | Gem. 예시 | Gem. 차이 | GPT6 기본 | GPT6 예시 | 차이 |
|---|---|---|---|---|---|---|---|
| T11 | 뉴스 요약문 | 63.8 | 76.2 | +12.5 | 93.1 | 98.1 | +5.0 |
| T12 | 과학 개념 설명글 | 50.0 | 80.0 | +30.0 | 100.0 | 100.0 | 0.0 |
| T13 | 북토크 후기 | 67.5 | 75.0 | +7.5 | 99.4 | 100.0 | +0.6 |
| T14 | 설득하는 글 | 52.5 | 65.0 | +12.5 | 98.8 | 100.0 | +1.2 |
| T15 | 하루 일기 | 62.5 | 85.0 | +22.5 | 100.0 | 99.4 | -0.6 |
| T16 | 동아리 지원 동기 | 55.0 | 83.8 | +28.8 | 97.5 | 100.0 | +2.5 |
| T17 | 발표 원고 | 57.5 | 71.2 | +13.8 | 95.6 | 96.2 | +0.6 |
| T18 | 짧은 동화 | 70.0 | 70.0 | 0.0 | 98.1 | 100.0 | +1.9 |

Gem.은 gemini-3.5-flash-lite(과제당 10 쌍), GPT6 은 gpt-6-luna(과제당 20 쌍)다.

## 3.9 사실 점검(교차 심판)

응답을 만든 회사와 다른 회사의 모델이 사실 목록으로 판정한 결과가 표 15 다. gemini-3.5-flash-lite 응답(gpt-6-luna 판정)의 사실 보존율은 기본 96.27%, 예시 제시 95.32%로 차이는 -0.94%p(구간 -3.29~+1.41, p=0.4415 )였다. 사전에 정한 기준(구간 상한 0 미만)에 해당하지 않으므로 예시가 사실 보존을 낮췄다는 증거는 없다. gpt-6-luna 응답(gemini-3.5-flash-lite 판정)은 기본 99.65%, 예시 제시 100.00%로 차이가 없었다. 지어낸 사실 수는 gemini-3.5-flash-lite 응답에서 예시 제시가 더 적었으나(1.67→1.30, 구간 -0.69~-0.07, 보정 전 p=0.0281 ), 지표 네 개를 함께 비교했으므로 Holm 보정을 하면 유의하지 않다(탐색용). 어조와 자연스러움 점수에서는 두 모델 모두 의미 있는 차이를 찾지 못했다.

**표 15. 사실 점검 결과 (교차 심판, 10 세트 100 쌍, 기본과 예시 제시)**

| 응답 / 심판 | 지표 | 기본 | 예시 제시 | 차이 | 95% 구간 | 순열 p |
|---|---|---|---|---|---|---|
| gemini-3.5 응답 / gpt-6 판정 | 사실 보존율(%) | 96.27 | 95.32 | -0.94 | -3.29 ~ +1.41 | 0.4415 |
| gemini-3.5 응답 / gpt-6 판정 | 지어낸 사실 수 | 1.67 | 1.30 | -0.37 | -0.69 ~ -0.07 | 0.0281 |
| gemini-3.5 응답 / gpt-6 판정 | 어조(1~5) | 4.53 | 4.42 | -0.11 | -0.23 ~ +0.02 | 0.1167 |
| gemini-3.5 응답 / gpt-6 판정 | 자연스러움(1~5) | 4.72 | 4.83 | +0.11 | +0.00 ~ +0.22 | 0.0906 |
| gpt-6 응답 / gemini-3.5 판정 | 사실 보존율(%) | 99.65 | 100.00 | +0.35 | +0.00 ~ +0.81 | 0.2560 |
| gpt-6 응답 / gemini-3.5 판정 | 지어낸 사실 수 | 0.13 | 0.19 | +0.06 | -0.13 ~ +0.23 | 0.6025 |
| gpt-6 응답 / gemini-3.5 판정 | 어조(1~5) | 4.97 | 4.92 | -0.05 | -0.11 ~ +0.01 | 0.1852 |
| gpt-6 응답 / gemini-3.5 판정 | 자연스러움(1~5) | 5.00 | 4.99 | -0.01 | -0.03 ~ +0.00 | 1.0000 |

이 결과는 앞의 내용 점검(표 10, 숫자·이름이 그대로 들어 있는지만 센 30 쌍에서 95.0%에서 87.8%)과 어긋나 보인다. 표 10 은 문자열 일치만 보는 단순한 지표이고 표 15 는 표 10 의 30 쌍을 포함한 100 쌍을 사실 목록으로 판정한 것이라 두 점검의 측정 대상이 다르다. 어느 쪽이 더 정확한지는 이 점검만으로는 확인하지 못했다.

### 3.10 예시의 길이와 내용 통제

3.5 절의 예시 변형은 내용 없는 형식 틀만으로도 예시와 비슷한 효과가 난다는 것을 보였지만 , 참고 글이 하나 더 붙어서 또는 글이 길어져서 생기는 효과인지는 가르지 못했다. 이를 확인하려고 gemini-3.5-flash-lite 에서 예시와 같은 내용의 줄글(L1)과 길이만 비슷한 무관한 글(L2)을 예시 대신 붙인 조건을 비교했다(10 세트, 조건당 100 쌍). 기본 조건은 67.6%, 예시 제시는 88.1%(+20.5%p, 구간 +16.6~+24.2)로 앞의 결과와 같은 크기였다. L1 은 63.1%로 기본 대비 -4.5%p(구간 -8.4~-0.6, 보정 전 p=0.030, Holm p=0.060)로 낮은 쪽이었으나 보정 후에는 유의하지 않았고, L2 는 68.2%(+0.6%p, 구간 -3.0~+4.4)로 기본과 같았다. 예시 제시와 직접 비교하면 L1 은 -25.0%p(구간 -28.5~-21.5), L2 는 -19.9%p(구간 -23.0~-16.8)였다. 미리 정한 기준에 따라 두 통제 조건 모두 '예시가 더 높음'으로 판정된다(표 16).

**표 16. 길이 통제 결과 (gemini-3.5-flash-lite, 10 세트, 조건당 100 쌍)**

| 조건 | 참고 글 | 준수율 (%) | 기본 대비 (%p) | 95% 구간 | 예시 대비 (%p) | 95% 구간 | 판정 |
|---|---|---|---|---|---|---|---|
| C00 | 없음 | 67.6 | 기준 | | | | |
| C04 | 예시(8 개 지시를 지킨 글) | 88.1 | +20.5 | +16.6 ~ +24.2 | 기준 | | |
| L1 | 같은 내용 줄글(형식 없음) | 63.1 | -4.5 | -8.4 ~ -0.6 | -25.0 | -28.5 ~ -21.5 | 예시가 더 높음 |
| L2 | 무관한 글(합니다체) | 68.2 | +0.6 | -3.0 ~ +4.4 | -19.9 | -23.0 ~ -16.8 | 예시가 더 높음 |

지시별로 보면(부록 B4, 탐색용) 참고 글이 형식을 갖추지 않았을 때 형식 지시의 통과율이 기본보다 낮아졌다. 소제목 4 줄은 기본 50%에서 L1 32%, 느낌표 1 회는 74%에서 39%였다. 이는 모델이 참고 글의 내용보다 모양을 따라 쓴다는 4.1 절의 해석과 같은 방향이지만, 이 실험으로 원인을 가린 것은 아니다. 한편 L1 과 L2 모두 첫 문장 20 자 이내 지시의 통과율이 기본(77%)보다 높아졌는데(97%, 97%) 이유는 확인하지 못했다.

### 3.11 지시를 12 개로 늘린 gpt-6-luna

3.6 절에서 gpt-6-luna 의 기본 준수율이 96.9%로 높아 요소 사이의 차이를 가릴 여지가 작았다. 이것이 지시 수가 적어서인지 보려고 지시를 12 개로 늘린 과제로 다시 비교했다(2.8 절, 8 세트, 조건당 64 쌍). 기본 조건의 준수율은 97.4%로 3.6 절과 거의 같아서, 지시를 늘려도 기본 준수율은 내려가지 않았다. 아홉 요소 모두 기본과의 차이가 10%p 이하였고 95% 구간은 모두 -5.3~+2.5%p 안에 있었다. 예시 제시는 98.3%(+0.9%p, 구간 -0.7~+2.5)였다. 보정 후에도 유의한 것은 번호 분할 하나였고 기본보다 3.3%p 낮았다(구간 -5.3~-1.2, Holm p=0.027). 이 차이는 10%p 기준에는 못 미친다. 지시별로 보면(부록 B5, 탐색용) 가장 어긋난 것은 '같은 끝 두 글자 3 연속 금지'로 기본 54/64 에서 번호 분할 36/64 로 떨어졌다.

**표 17. 지시 12 개 과제에서 gpt-6-luna 의 요소별 결과 (8 세트, 조건당 64 쌍)**

| 조건 | 이름 | 준수율(%) | 기본 대비 (%p) | 95% 구간 | 순열 p | Holm p | 10%p 기준 |
|---|---|---|---|---|---|---|---|
| C00 | 기본 | 97.4 | 기준 | | | | |
| C01 | 형식 지정 | 96.0 | -1.4 | -3.9 ~ +0.9 | 0.301 | 1.000 | 구분 안 됨 |
| C02 | 번호 분할 | 94.1 | -3.3 | -5.3 ~ -1.2 | 0.003 | 0.027 | 구분 안 됨 |
| C03 | 제약 명시 | 97.1 | -0.3 | -2.7 ~ +2.1 | 0.918 | 1.000 | 구분 안 됨 |
| C04 | 예시 1 개 | 98.3 | +0.9 | -0.7 ~ +2.5 | 0.352 | 1.000 | 구분 안 됨 |
| C05 | 역할 부여 | 98.0 | +0.7 | -0.8 ~ +2.1 | 0.480 | 1.000 | 구분 안 됨 |
| C06 | 출력 길이 지정 | 96.1 | -1.3 | -3.0 ~ +0.4 | 0.182 | 1.000 | 구분 안 됨 |
| C07 | 핵심 지시 맨 앞 | 97.7 | +0.3 | -1.7 ~ +2.2 | 0.899 | 1.000 | 구분 안 됨 |
| C08 | 핵심 지시 맨 끝 | 97.3 | -0.1 | -2.0 ~ +1.7 | 1.000 | 1.000 | 구분 안 됨 |
| C09 | 자기 점검 요청 | 97.5 | +0.1 | -1.3 ~ +1.6 | 1.000 | 1.000 | 구분 안 됨 |

따라서 3.6 절의 천장은 지시가 8 개뿐이어서만 생긴 것이 아니다. gpt-6-luna 는 이런 형식·구조·문체 지시를 12 개까지는 요소를 더하지 않아도 거의 다 지켰다. 다만 올라갈 여지가 3%p 도 안 되므로 요소가 효과가 없다고 단정할 수는 없고, 이 설정에서 10%p 이상의 효과는 없다는 정도로 읽어야 한다. 더 어려운 종류의 지시에서는 확인하지 못했다.

## 3.12 다른 예시

지금까지의 예시 제시 조건은 도서관 이용 안내라는 한 예시를 썼다. 예시의 주제와 문장 구성을 바꿔도 효과가 같은지 보려고 gemini-3.5-flash-lite 에서 다른 예시 두 개를 같은 방식으로 비교했다(2.8 절, 10 세트, 조건당 100 쌍). 기본 조건은 67.5%, 도서관 예시는 87.8%(+20.2%p)였고, E1 은 88.0%(+20.5%p, 구간 +17.4~+23.8), E2 는 85.0%(+17.5%p, 구간 +14.1~+20.9)로 모두 Holm 보정 후 $p<0.001$ 이었다. 미리 정한 기준에 따라 두 예시 모두 '효과 유지'로 판정된다(표 18). 도서관 예시와 직접 비교하면 E1 은 +0.2%p(구간 -2.2~+2.8), E2 는 -2.8%p(구간 -5.2~-0.2, 보정 전 $p=0.044$)였다. E2 가 약간 낮은 쪽이지만 보정하지 않은 탐색용 값이다.

**표 18. 다른 예시의 효과 (gemini-3.5-flash-lite, 10 세트, 조건당 100 쌍)**

| 조건 | 예시 | 준수율 (%) | 기본 대비 (%p) | 95% 구간 | 도서관 예시 대비(%p) | 판정 |
|---|---|---|---|---|---|---|
| C00 | 없음 | 67.5 | 기준 | | | |
| C04 | 도서관 이용 안내(10 문장) | 87.8 | +20.2 | +17.0 ~ +23.5 | 기준 | |
| E1 | 헌 옷 수거 안내(12 문장) | 88.0 | +20.5 | +17.4 ~ +23.8 | +0.2 [-2.2, +2.8] | 효과 유지 |
| E2 | 분리배출 안내(10 문장) | 85.0 | +17.5 | +14.1 ~ +20.9 | -2.8 [-5.2, -0.2] | 효과 유지 |

지시별로 보면(부록 B6, 탐색용) 소제목 4 줄과 문단 4 개는 세 예시 모두 100%였다. 전체 10~14 문장 지시는 10 문장 예시(도서관, E2)에서 46%, 50%였고 12 문장 예시(E1)에서 65%로 더 높았다. 응답의 문장 수가 예시의 문장 수를 따라가기 쉬워 예시를 범위의 가운데로 잡는 편이 유리할 수 있다는 해석이 가능하지만 이 실험으로 확인한 것은 아니다. 첫 문장 20 자 이내는 E1 에서 60%로 낮았고(도서관 75%, E2

88%), 느낌표 1 회는 E2 에서 56%로 낮았다(도서관 86%, E1 94%). 이유는 확인하지 못했다. 예시마다 효과가 닿는 지시가 조금씩 다르다는 점은 3.5 절의 예시 변형과 같다.

같은 비교를 gpt-6-luna 에서도 했다(10 세트, 조건당 100 쌍). 기본 조건은 95.4%였고 도서관 예시는 99.4%(+4.0%p, 구간 +1.5~+6.9, Holm p=0.008), E1 은 97.8%(+2.4%p, 구간 +0.0~+5.1, Holm p=0.114), E2 는 98.2%(+2.9%p, 구간 +0.1~+5.8, Holm p=0.114)였다. 세 예시 모두 기본보다 높은 쪽이었지만 기본이 이미 95.4%라 올라갈 여지가 5%p 도 안 되어 10%p 기준에는 못 미쳤고, 미리 정한 기준으로는 두 예시 모두 '효과 불분명'이다. 이는 효과가 없다는 뜻이 아니라 이 모델에서는 효과를 가릴 여지가 작다는 뜻이다(3.6, 3.11 절과 같다). 도서관 예시와 직접 비교하면 E1 은 -1.6%p(구간 -3.4~-0.1), E2 는 -1.1%p(구간 -2.8~+0.2)로 새 예시가 약간 낮은 쪽이었으나 보정하지 않은 탐색용 값이다(표 19). 지시별로 보면(부록 B7) 새 예시에서는 해요체가 94%, 97%로 도서관 예시(99%)보다 낮았다. 이유는 확인하지 못했다.

**표 19. 다른 예시의 효과 (gpt-6-luna, 10 세트, 조건당 100 쌍)**

| 조건 | 예시 | 준수율 (%) | 기본 대비 (%p) | 95% 구간 | 도서관 예시 대비(%p) | 10%p 기준 |
|---|---|---|---|---|---|---|
| C00 | 없음 | 95.4 | 기준 | | | |
| C04 | 도서관 이용 안내(10 문장) | 99.4 | +4.0 | +1.5 ~ +6.9 | 기준 | 구분 안 됨 |
| E1 | 헌 옷 수거 안내(12 문장) | 97.8 | +2.4 | +0.0 ~ +5.1 | -1.6 [-3.4, -0.1] | 구분 안 됨 |
| E2 | 분리배출 안내(10 문장) | 98.2 | +2.9 | +0.1 ~ +5.8 | -1.1 [-2.8, +0.2] | 구분 안 됨 |

# 4. 논의

## 4.1 예시 제시가 효과적이었던 이유에 대한 해석

이 실험은 원인을 직접 검증하지 않았으므로 아래는 해석이다. 예시 제시 조건의 예시는 8 개 지시를 모두 지킨 글이다. 모델은 '소제목은 정확히 4 줄' 같은 규칙을 말로 풀어 읽는 대신 예시의 모양(소제목 줄, 문단 구분, 해요체의 문장 길이)을 따라 쓴 것으로 보인다. 소제목·문단·문체처럼 눈에 보이는 모양으로 드러나는 지시에서 개선이 가장 컸고(거의 100%), 전체 문장 수처럼 모양보다 합계로 정해지는 지시는 개선되지 않았다. 예시 제시의 출력이 평균 217 자로 기본(282 자)보다 짧아진 것도 예시(약 10 문장)를 따라 쓴 결과로 읽을 수 있고, 이 경우 전체 문장 수가 하한 10 문장 아래로 내려갈 수 있다.

예시와 지시가 어긋나는 조건(3.7 절)에서 이 해석은 일부만 맞았다. gemini-3.5-flash-lite 는 합니다체 예시의 문체에 끌려 해요체 지시를 더 어겼으므로 문체의 모방은 실제로 작용한다. 그러나 소제목과 문단을 5 개로 쓴 예시를 주어도 4 개로 쓰라는 지시를 지켰고 통과율은 기본(48%)보다 올랐다. 따라서 예시의 효과를 모양의 모방 하나로만 설명할 수는 없고, 예시가 있으면 지시를 다시 읽게 되는 효과가 함께 있을 수 있다. 이는 해석이며 이 실험으로 둘을 구분하지는 못했다.

보강 실험은 이 해석을 뒷받침한다. 내용 없는 형식 틀만 보여 주어도 예시 글과 거의 같은 효과(+20.2%p 대 +21.6%p)가 났고, 예시를 2 개로 늘려도 더 좋아지지 않았다. 효과를 낸 것은 예시의 내용이 아니라 글의 모양(소제목 줄, 문단 수, 문단당 문장 수)을 보여 준 것으로 보인다.

길이 통제(3.10 절)도 이 해석과 맞는다. 예시와 같은 내용이지만 모양을 갖추지 않은 줄글은 기본보다 오히려 약간 낮았고(-4.5%p) 길이만 비슷한 무관한 글은 기본과 같았다(+0.6%p). 예시의 효과는 참고 글이 길어서도, 요청한 내용과 같은 정보를 담아서도 아니고 지시를 지킨 모양을 보여 준 데서 나온 것으로 보인다. 다만 이 실험은 여전히 원인을 직접 가르지는 못한다.

다른 예시 실험(3.12 절)에서 gemini-3.5-flash-lite 는 주제와 문장 구성이 다른 예시 두 개로도 도서관 예시와 비슷한 효과를 냈다. 효과가 특정 예시의 내용에 묶여 있지 않다는 뜻이다. gpt-6-luna 에서는 세 예시 모두 기본보다 높은 쪽이었지만 천장이라 크기를 가리지 못했다 . 다만 이것도 원인을 직접 가르지는 않는다.

### 4.2 효과가 없었던 요소

번호 분할, 제약 명시, 출력 길이 지정, 자기 점검 요청, 핵심 지시의 위치는 gemini-3.5-flash-lite 와 이 과제에서 기본과 구분되지 않았다. 기본 준수율이 73.3%여서 올라갈 여지(26.7%p)는 충분했으므로 천장 효과로 설명하기 어렵다. 자기 점검 요청은 한 번의 호출 안에서 점검을 요구하는 방식이라 실제로 점검 과정이 응답에 드러나지 않아 효과가 작았을 수 있다. 핵심 지시를 프롬프트의 맨 앞이나 맨 끝으로 옮기는 효과도 보이지 않았는데, 이 실험의 프롬프트는 짧아서 위치의 영향이 작을 수 있다(Liu et al., 2024 는 긴 입력을 다뤘다).

gpt-6-luna 에서는 아홉 요소 모두 기본과 구분되지 않았다(3.6 절). 기본 준수율이 96.9%로 천장에 가까워 요소가 효과를 낼 여지가 작았기 때문이며, 이를 요소가 효과가 없다는 뜻으로 읽을 수는 없다. 지시를 12 개로 늘린 3.11 절에서도 같았다.

형식 지정과 역할 부여는 낮아지는 경향이 있었다. 10 세트 합산에서도 각각 -5.5%p, -4.8%p 로 낮은 쪽이었으나 보정 후에는 유의하지 않았다. 형식 지정 조건은 '맨 첫 줄에는 제목만'이라는 지시를 더하는데, 이것이 기본 지시의 문단 구조(소제목 4 줄, 첫 문단 2 문장)와 겹쳐 혼란을 일으켰을 수 있다(첫 문단 2 문장 지시가 주 실험 30 회에서 80%에서 47%로, 10 세트 합산에서 68%에서 48%로 떨어졌다). 이는 해석이며 이 실험만으로는 확인되지 않는다. 역할 부여가 도움이 되지 않았다는 점은 선행 보고(Zheng et al., 2024)와 방향이 같다.

### 4.3 실용적 시사점

이 결과에서 곧바로 말할 수 있는 것은 하나다. gemini-3.5-flash-lite 에서는 같은 지시를 주더라도, 지시를 모두 지킨 예시 글을 하나 붙이면 형식·구조·문체 지시의 준수율이 크게 오른다. 기본 준수율이 이미 97% 가까운 gpt-6-luna 에서는 이 효과가 작았고, 지시를 12 개로 늘려도 마찬가지였다(3.11 절). 반면 지시를 번호로 나누거나, 금지 사항을 따로 적거나, 역할을 맡기거나, 스스로 점검하라고 하는 것은 두 모델 모두에서 눈에 띄는 이점이 없었다. 지시를 늘 지키게 하려는 도구라면, 규칙 설명을 다듬는 데 시간을 쓰기보다 규칙을 지킨 예시를 자동으로 붙여 주는 쪽이 (기본 준수율이 낮은 모델에서는) 더 효과가 크리라고 기대할 수 있다.

보강 실험은 세 가지를 더 알려 준다. 첫째, 예시가 길거나 여러 개일 필요는 없다. 예시 1 개나 내용 없는 형식 틀이면 충분했고 예시의 주제가 달라도 효과가 비슷했다(3.12 절, gemini-3.5-flash-lite). 형식 틀은 전체 문장 수 지시까지 개선했지만(68%에서 83%) 첫 문장 길이 지시는 낮췄다(83%에서 59%). 지시마다 효과가 달라서 틀에 길이나 개수 정보를 함께 담는 설계가 필요하다. 둘째, 예시를 붙인 응답은 평균 66 자 짧아졌고, 숫자·이름 일치로 센 사실 보존율은 95.0%에서 87.8%로 낮았다(30 쌍). 그러나 교차 심판이 100 쌍씩 사실 목록으로 판정한 보존율은 두 모델 모두 예시 제시에서 낮아지지 않았다(3.9 절). 내용 손실은 이 실험에서 일관되게 확인되지 않았지만 판정 방법에 따라 결과가 엇갈렸으므로 , 형식 규칙과 함께 '아래

사실을 모두 포함해 줘' 같은 내용 지시와 사실 포함 여부의 점검을 같이 두는 것이 좋다. 셋째, 예시는 지시와 어긋나지 않게 써야 한다. gemini-3.5-flash-lite 에서 합니다체 예시를 주자 해요체 지시 통과율이 87%에서 74%로 기본보다도 낮아졌다(3.7 절). gpt-6-luna 는 이런 어긋남에도 지시를 따랐다.

모델에 따른 차이도 있었다. 기본 준수율이 높은 모델일수록 예시의 효과는 작았다(gemini-3.5-flash-lite 69.5% 에서 +18.4%p, gemini-3.1-flash-lite 80.4% 에서 +12.5%p, gpt-5.6-luna 91.0% 에서 +6.3%p, gpt-6-luna 96.2%에서 +1.7%p). 모델이 서로 다르므로 이 경향이 기본 점수 때문인지 모델의 다른 특성 때문인지는 이 실험으로 구분하지 못한다. 기본 점수가 이미 높은 모델에서는 예시가 줄 수 있는 몫이 작으므로, 예시의 비용(응답이 짧아지는 것, 사실이 빠질 가능성)과 효과를 모델마다 따져 보아야 한다. gpt-6-luna 응답의 사실 보존은 3.9 절에서 점검했다.

한 가지 결과가 더 있다. 8 개 지시 중 숫자를 맞춰야 하는 지시(문단 4 개, 문장 수 범위)는 예시가 없으면 약 50~70%밖에 지켜지지 않았다. 지시 준수를 믿고 쓰려면 응답이 지시를 지켰는지 사후에 점검하는 단계가 필요하다는 점을 시사한다. 이 연구의 채점 규칙이 그 점검의 출발점이 될 수 있다.

## 5. 한계

- **모델과 환경.** 주 모델은 gemini-3.5-flash-lite 와 gpt-6-luna 두 개이고 아홉 요소는 이 두 모델에서만 비교했다. 같은 계열의 gemini-3.1-flash-lite 와 OpenAI 의 gpt-5.6-luna 는 기본과 예시 제시만 확인했다. 모두 소형·기본 등급 모델이며 대형 모델은 포함하지 않았다. 호출은 API 로 했고 생성 설정(온도, 추론 강도 등)은 기본값이다. 일반 사용자가 쓰는 대화 서비스에는 API 와 다른 시스템 지시문이 붙을 수 있어 같은 결과가 나온다고 보장할 수 없다. 모델이 갱신되면 결과가 달라질 수 있다. gpt-6-luna 를 일반 사용자의 기본 모델로 본 것은 서비스 화면에서의 확인에 근거하며 모든 지역·요금제에서 같은지는 확인하지 않았다.
- **난이도를 맞춘 표본.** 지시는 기본 조건에서 통과율이 중간 범위인 것을 골랐다(부록 D). 모델이 흔들리는 지시를 모은 셈이라 실제 사용 환경의 지시를 대표하지 않는다. 이 선택은 gemini-3.5-flash-lite 의 기본 조건을 기준으로 했다. gpt-6-luna 는 같은 지시를 조정 없이 받아 천장에 가까웠다(3.6, 3.11 절). 더 어려운 종류의 지시(내용 지시, 추론 등)에서 요소의 효과가 나타나는지는 확인하지 못했다.
- **문자열 규칙 채점.** 주 실험은 지시를 지켰는지만 규칙으로 판정했다. 내용은 보강 실험에서 작은 AI 심판(gemma), 교차 심판(응답을 만든 회사와 다른 회사의 소형 모델), 숫자·이름 일치라는 단순 지표로만 점검했고, 이 점검의 일부(내용 보존)는 결과를 본 뒤에 추가한 사후 분석이다. 사실 정확성의 정밀한 검증은 하지 않았다. 점검 방법 사이에 결과가 엇갈렸으므로 내용 질에 대한 결론은 약하다. 문장 나누기도 마침표 기준의 단순한 규칙이라 예외(줄임표, 목록 줄 등)에서 오판이 있을 수 있다. 8 개 지시를 같은 가중으로 합산했다.
- **과제와 지시의 범위.** 과제는 한국어 글쓰기(주 실험 10 개, 보강 8 개)이고 지시는 형식·구조·문체다. 코드, 추론처럼 다른 종류의 과제나 내용 지시에는 적용하지 못한다.
- **예시의 범위.** 예시 제시 조건은 도서관 이용 안내 한 예시를 모든 과제에 썼고, 3.12 절에서 주제와 문장 구성이 다른 예시 두 개를 두 주 모델에서 더 확인했다. 그래도 세 예시는 모두 소제목 줄이 있는 안내문 형식이고, gpt-6-luna 에서는 천장 때문에 효과의 크기를 가리지 못했으며, 전혀 다른 모양의 예시에서 효과가 같은지는 모른다. 예시는 8 개 지시를 모두 지켰으므로 효과가 '예시'

때문인지 '지시를 지킨 정답을 보여 준 것' 때문인지 구분하지 못한다. 예시의 길이와 내용은 3.10 절에서 통제했다. 예시와 지시가 어긋나는 경우(3.7)도 두 가지 어긋남만 확인했다.

- **조건 구성의 겹침.** 형식 지정 조건처럼 추가 지시가 기본 지시와 겹치는 조건은 순수한 형식 지정의 효과가 아니라 지시 사이의 충돌을 함께 잰 것일 수 있다.
- **다중비교와 표본 크기.** 조건 9 개를 동시에 비교했고 짝 비교는 주 실험에서 30 개, 반복을 합쳐도 100 개다. 95% 구간은 다중비교를 보정하지 않았고, 지시별 검정은 탐색용이다. 작은 효과는 이 표본으로 확인되지 않는다.
- **실행 시기.** 주 실험의 호출이 하루를 넘겨 이어졌다(10 월 12 일 16:10 ~ 13 일 09:09). 반복·보강 실험은 10 월 14 일부터 22 일 사이에 했다. 같은 조건이 같은 시간대에 몰리지 않도록 순서를 섞었지만, 모델 쪽의 변화가 있었다면 알 수 없다.
- **확증과 확인.** 반복 분량은 결과를 보기 전에 정했고 전부 보고했다. 보강 실험(예시 변형, 다른 모델, OpenAI 모델, gpt-6-luna 아홉 요소, 어긋나는 예시, 다른 글 종류, 내용 질과 사실 점검, 길이 통제, 지시 12 개, 다른 예시)은 주 실험 결과를 본 뒤에 설계한 확인 실험이며, 각 실험의 분량과 판정 기준은 해당 데이터를 얻기 전에 정했다.

## 6. 결론

프롬프트에 포함하는 구조적 요소의 종류에 따라 지시 준수율이 달라진다는 가설은 모델에 따라 다르게 지지되었다. gemini-3.5-flash-lite 에서는 아홉 요소 가운데 예시 제시만 기본보다 뚜렷하게 높았고 (처음 30 쌍 +16.7%p, 10 세트 100 쌍 합산 +18.4%p, 보정 후 $p<0.001$) 나머지 여덟 요소는 기본과 구분되지 않았다. 효과의 대부분은 소제목, 문단, 문체처럼 모양으로 드러나는 지시에서 나왔고, 예시 1 개, 예시 2 개, 내용 없는 형식 틀이 비슷한 효과 (+20.2~+22.5%p)를 보였고, 주제와 문장 구성이 다른 예시 두 개도 도서관 예시와 비슷했다 (+20.5%p, +17.5%p; gpt-6-luna 에서는 세 예시 모두 소폭 높았다). 안내문이 아닌 글 8 종에서도 같은 방향이었다 (+15.9%p, 다만 짧은 동화에서는 차이가 없었다). 예시와 비슷한 길이의 통제 글(같은 내용의 줄글, 무관한 글)은 예시만큼 효과를 내지 못해서 (예시보다 각각 25%p, 19.9%p 낮음) 효과가 글의 길이나 내용만으로는 설명되지 않는다. 반면 예시가 지시와 어긋나면 결과가 달라서, 합니다체 예시는 해요체 지시를 오히려 어기게 했다(87%에서 74%).

gpt-6-luna 에서는 기본 준수율이 96.9%로 이미 천장에 가까워 아홉 요소 어느 것도 기본과 구분되지 않았고 예시 제시도 +2.0%p 에 그쳤다. 다른 소형 모델(gemini-3.1-flash-lite +12.5%p, gpt-5.6-luna +6.3%p)에서도 방향은 같았고 기본 준수율이 높을수록 효과가 작았다. 지시를 12 개로 늘린 과제에서도 gpt-6-luna 의 기본 준수율은 97.4%로 높았고 어느 요소도 10%p 이상의 차이를 내지 않았다. 내용은 판정 방법에 따라 엇갈렸다. 작은 심판(gemma)과 숫자·이름 일치 지표는 예시 조건을 낮게 보았지만 (승률 16.7%, 보존율 95.0%에서 87.8%), 교차 심판이 사실 목록으로 100 쌍씩 점검한 사실 보존율에는 두 모델 모두 차이가 없었다. 따라서 형식 지시를 자주 어기는 모델에는 지시와 어긋나지 않는 예시나 형식 틀을 붙이고 사실이 빠졌는지를 함께 점검하는 것이 이 연구가 권하는 설계다. 이 결과는 소형·기본 등급 모델과 한국어 글쓰기 과제에 한정되며, 대형 모델과 다른 종류의 지시에서의 반복이 필요하다.

## 참고문헌


Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., et al. (2020). Language models are few-shot learners. Advances in Neural Information Processing Systems, 33, 1877-1901.

Efron, B., & Tibshirani, R. J. (1993). An Introduction to the Bootstrap. Chapman & Hall.

He, J., Rungta, M., Koleczek, D., Sekhon, A., Wang, F. X., & Hasan, S. (2024). Does prompt formatting have any impact on LLM performance? arXiv:2411.10541.

Holm, S. (1979). A simple sequentially rejective multiple test procedure. Scandinavian Journal of Statistics, 6(2), 65-70.

Liu, N. F., Lin, K., Hewitt, J., Paranjape, A., Bevilacqua, M., Petroni, F., & Liang, P. (2024). Lost in the middle: How language models use long contexts. Transactions of the Association for Computational Linguistics, 12, 157-173.

Madaan, A., Tandon, N., Gupta, P., Hallinan, S., Gao, L., Wiegreffe, S., et al. (2023). Self-Refine: Iterative refinement with self-feedback. arXiv:2303.17651.

Sclar, M., Choi, Y., Tsvetkov, Y., & Suhr, A. (2023). Quantifying language models' sensitivity to spurious features in prompt design or: How I learned to start worrying about prompt formatting. arXiv:2310.11324.

Zheng, M., Pei, J., Logeswaran, L., Lee, M., & Jurgens, D. (2024). When "a helpful assistant" is not really helpful: Personas in system prompts do not improve performances of large language models. Findings of the Association for Computational Linguistics: EMNLP 2024, 15126-15154.

Zhou, J., Lu, T., Mishra, S., Brahma, S., Basu, S., Luan, Y., Zhou, D., & Hou, L. (2023). Instruction-following evaluation for large language models. arXiv:2311.07911.

## 부록 A. 프롬프트 예 (과제 T01)

### 기본 조건(C00)

클라우드 노트 서비스 'MSK 노트'의 이용약관 변경 안내문을 작성해 줘. 변경 사항은 세 가지야. 개인정보 보관 기간이 1 년에서 6 개월로 줄어들고 요금제 이름이 베이직에서 스타터로 바뀌고 삭제한 데이터는 30 일 뒤에 영구 삭제돼. 시행일은 11 월 15 일이고 동의하지 않는 이용자는 11 월 14 일까지 탈퇴할 수 있어. 소제목은 '▶'로 시작하는 줄 정확히 4 줄로 쓰고, 문단은 빈 줄로 나누어 정확히 4 개로 쓰고, 첫 문단은 두 문장으로 쓰고, 느낌표(!)는 전체에서 정확히 한 번만 쓰고, 한 문단은 2 문장에서 4 문장 사이로 쓰고, 전체 문장 수는 10 문장에서 14 문장 사이로 쓰고, 모든 문장은 '~요'로 끝나는 해요체로 쓰고, 첫 문장은 공백 포함 20 자 이내로 써 줘.

### 예시 제시 조건(C04)에서 덧붙이는 예시

예시(내용은 다르지만 위 지시를 모두 지킨 글이야):
▶ 도서관 이용 안내
이번 달부터 도서관이 달라져요. 열람실 운영 시간이 조금 바뀌어요.

▶ 운영 시간
평일에는 오전 9 시에 문을 열어요. 저녁 8 시까지 열람실을 이용할 수 있어요. 주말에는 오후 6 시에 문을 닫아요.

▶ 대출 방법
책은 한 번에 다섯 권까지 빌릴 수 있어요. 대출 기간은 2 주예요! 기간이 끝나기 전에 연장도 가능해요.

▶ 문의
궁금한 점은 안내 데스크에 편하게 물어보세요. 전화로도 문의할 수 있어요.

## 부록 B. 지시별 통과 횟수 (조건당 30 회 중)

**표 B1. 지시별 통과 횟수 (gemini-3.5-flash-lite, 주 실험 세트 1~3, 조건당 30 회 중)**

| 조건 | 이름 | 소제목 4 줄 | 문단 4 개 | 첫 문단 2 문장 | 느낌표 1 회 | 문단당 2~4 문장 | 전체 10~14 문장 | 해요체 | 첫 문장 20 자 |
|---|---|---|---|---|---|---|---|---|---|
| C00 | 기본 | 17 | 15 | 24 | 26 | 24 | 21 | 23 | 26 |
| C01 | 형식 지정 | 18 | 14 | 14 | 20 | 24 | 21 | 21 | 21 |
| C02 | 번호 분할 | 21 | 20 | 26 | 22 | 28 | 17 | 25 | 20 |
| C03 | 제약 명시 | 17 | 21 | 23 | 18 | 27 | 21 | 29 | 24 |
| C04 | 예시 제시 | 30 | 30 | 29 | 29 | 30 | 16 | 30 | 22 |
| C05 | 역할 부여 | 20 | 16 | 18 | 23 | 21 | 14 | 21 | 24 |
| C06 | 출력 길이 지정 | 20 | 17 | 24 | 23 | 26 | 22 | 24 | 22 |
| C07 | 핵심 지시 맨 앞 | 19 | 18 | 18 | 28 | 22 | 19 | 27 | 22 |
| C08 | 핵심 지시 맨 끝 | 12 | 18 | 18 | 26 | 20 | 17 | 26 | 27 |

| 조건 | 이름 | 소제목 4 줄 | 문단 4 개 | 첫 문단 2 문장 | 느낌표 1 회 | 문단당 2~4 문장 | 전체 10~14 문장 | 해요체 | 첫 문장 20 자 |
|---|---|---|---|---|---|---|---|---|---|
| C09 | 자기 점검 요청 | 18 | 18 | 20 | 22 | 24 | 20 | 28 | 24 |

보정 전 Fisher 정확검정($p<0.05$)에서 기본과 달라진 지시: 형식 지정의 첫 문단 2 문장(80→47%), 제약 명시의 느낌표 1 회(87→60%), 예시 제시의 소제목 4 줄(57→100%), 문단 4 개(50→100%), 문단당 2~4 문장(80→100%), 해요체(77→100%).

**표 B2. 지시별 통과 횟수 (gemini-3.5-flash-lite, 10 세트 합산, 조건당 100 회 중)**

| 조건 | 이름 | 소제목 4 줄 | 문단 4 개 | 첫 문단 2 문장 | 느낌표 1 회 | 문단당 2~4 문장 | 전체 10~14 문장 | 해요체 | 첫 문장 20 자 |
|---|---|---|---|---|---|---|---|---|---|
| C00 | 기본 | 50/100 | 54/100 | 68/100 | 72/100 | 79/100 | 66/100 | 84/100 | 83/100 |
| C01 | 형식 지정 | 59/100 | 54/100 | 48/100 | 71/100 | 82/100 | 68/100 | 71/100 | 59/100 |
| C02 | 번호 분할 | 68/100 | 60/100 | 79/100 | 71/100 | 90/100 | 60/100 | 77/100 | 67/100 |
| C03 | 제약 명시 | 57/100 | 59/100 | 66/100 | 74/100 | 81/100 | 67/100 | 91/100 | 82/100 |
| C04 | 예시 1 개 | 100/100 | 100/100 | 93/100 | 91/100 | 97/100 | 50/100 | 100/100 | 72/100 |
| C05 | 역할 부여 | 63/100 | 53/100 | 61/100 | 74/100 | 69/100 | 48/100 | 71/100 | 79/100 |
| C06 | 출력 길이 지정 | 72/100 | 54/100 | 67/100 | 67/100 | 80/100 | 70/100 | 83/100 | 68/100 |
| C07 | 핵심 지시 맨 앞 | 60/100 | 52/100 | 64/100 | 94/100 | 68/100 | 58/100 | 93/100 | 76/100 |
| C08 | 핵심 지시 맨 끝 | 49/100 | 51/100 | 61/100 | 85/100 | 69/100 | 66/100 | 82/100 | 83/100 |
| C09 | 자기 점검 요청 | 51/100 | 57/100 | 66/100 | 66/100 | 81/100 | 64/100 | 87/100 | 78/100 |

**표 B3. 지시별 통과 횟수 (gpt-6-luna, 10 세트, 조건당 100 회 중)**

| 조건 | 이름 | 소제목 4 줄 | 문단 4 개 | 첫 문단 2 문장 | 느낌표 1 회 | 문단당 2~4 문장 | 전체 10~14 문장 | 해요체 | 첫 문장 20 자 |
|---|---|---|---|---|---|---|---|---|---|
| C00 | 기본 | 100/100 | 100/100 | 90/100 | 100/100 | 97/100 | 96/100 | 94/100 | 98/100 |
| C01 | 형식 지정 | 99/100 | 96/100 | 90/100 | 99/100 | 90/100 | 89/100 | 92/100 | 97/100 |
| C02 | 번호 분할 | 100/100 | 100/100 | 88/100 | 98/100 | 96/100 | 93/100 | 95/100 | 98/100 |
| C03 | 제약 명시 | 100/100 | 99/100 | 90/100 | 98/100 | 93/100 | 87/100 | 95/100 | 98/100 |
| C04 | 예시 1 개 | 100/100 | 100/100 | 100/100 | 100/100 | 100/100 | 92/100 | 99/100 | 100/100 |
| C05 | 역할 부여 | 100/100 | 100/100 | 92/100 | 100/100 | 93/100 | 90/100 | 97/100 | 96/100 |
| C06 | 출력 길이 지정 | 100/100 | 100/100 | 91/100 | 100/100 | 96/100 | 96/100 | 97/100 | 99/100 |
| C07 | 핵심 지시 맨 앞 | 100/100 | 99/100 | 84/100 | 99/100 | 94/100 | 89/100 | 92/100 | 98/100 |
| C08 | 핵심 지시 맨 끝 | 100/100 | 100/100 | 97/100 | 99/100 | 99/100 | 94/100 | 98/100 | 100/100 |
| C09 | 자기 점검 요청 | 100/100 | 100/100 | 91/100 | 99/100 | 96/100 | 93/100 | 96/100 | 96/100 |

**표 B4. 지시별 통과 횟수 (길이 통제, gemini-3.5-flash-lite, 10 세트, 조건당 100 회 중)**

| 조건 | 참고 글 | 소제목 4 줄 | 문단 4 개 | 첫 문단 2 문장 | 느낌표 1 회 | 문단당 2~4 문장 | 전체 10~14 문장 | 해요체 | 첫 문장 20 자 |
|---|---|---|---|---|---|---|---|---|---|
| C00 | 없음 | 50/100 | 49/100 | 67/100 | 74/100 | 77/100 | 64/100 | 83/100 | 77/100 |
| C04 | 예시 | 100/100 | 100/100 | 94/100 | 87/100 | 99/100 | 53/100 | 99/100 | 73/100 |
| L1 | 같은 내용 줄글 | 32/100 | 48/100 | 60/100 | 39/100 | 68/100 | 71/100 | 90/100 | 97/100 |
| L2 | 무관한 글 | 39/100 | 48/100 | 59/100 | 70/100 | 70/100 | 74/100 | 89/100 | 97/100 |

**표 B5. 지시별 통과 횟수 (지시 12 개, gpt-6-luna, 8 세트, 조건당 64 회 중, 표에는 통과한 횟수만)**

| 조건 | 이름 | 소제목 | 문단 | 첫 문단 | 느낌표 | 문단당 | 전체 문장 | 해요체 | 첫 문장 | 물음표 | 금지어 | 40 자 | 어미 |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| C00 | 기본 | 64 | 64 | 63 | 64 | 63 | 61 | 63 | 63 | 63 | 64 | 62 | 54 |
| C01 | 형식 지정 | 64 | 61 | 60 | 62 | 62 | 62 | 62 | 64 | 61 | 64 | 64 | 51 |
| C02 | 번호 분할 | 64 | 64 | 55 | 63 | 63 | 62 | 64 | 64 | 63 | 64 | 61 | 36 |
| C03 | 제약 명시 | 64 | 62 | 62 | 63 | 63 | 62 | 63 | 63 | 61 | 64 | 62 | 57 |
| C04 | 예시 1 개 | 64 | 64 | 63 | 61 | 63 | 64 | 64 | 64 | 64 | 64 | 64 | 56 |
| C05 | 역할 부여 | 64 | 64 | 63 | 63 | 64 | 64 | 64 | 64 | 64 | 64 | 64 | 51 |
| C06 | 출력 길이 지정 | 64 | 64 | 60 | 62 | 62 | 62 | 63 | 63 | 63 | 64 | 59 | 52 |
| C07 | 핵심 지시 맨 앞 | 64 | 64 | 61 | 64 | 63 | 63 | 64 | 61 | 63 | 64 | 63 | 56 |
| C08 | 핵심 지시 맨 끝 | 64 | 62 | 62 | 64 | 63 | 61 | 63 | 64 | 62 | 64 | 63 | 55 |
| C09 | 자기 점검 요청 | 64 | 63 | 63 | 64 | 63 | 61 | 63 | 64 | 63 | 64 | 61 | 56 |

열 이름은 앞의 여덟 개가 기본 지시 8 개(표 B3 과 같은 순서)이고 뒤의 네 개는 물음표 정확히 1 회, 금지어 3 개 없음, 모든 문장 40 자 이내, 같은 끝 두 글자 3 연속 없음(어미)이다.

**표 B6. 지시별 통과 횟수 (다른 예시, gemini-3.5-flash-lite, 10 세트, 조건당 100 회 중)**

| 조건 | 예시 | 소제목 4 줄 | 문단 4 개 | 첫 문단 2 문장 | 느낌표 1 회 | 문단당 2~4 문장 | 전체 10~14 문장 | 해요체 | 첫 문장 20 자 |
|---|---|---|---|---|---|---|---|---|---|
| C00 | 없음 | 45/100 | 45/100 | 68/100 | 66/100 | 71/100 | 73/100 | 90/100 | 82/100 |
| C04 | 도서관(10 문장) | 100/100 | 100/100 | 96/100 | 86/100 | 99/100 | 46/100 | 100/100 | 75/100 |
| E1 | 헌 옷 수거(12 문장) | 100/100 | 100/100 | 88/100 | 94/100 | 98/100 | 65/100 | 99/100 | 60/100 |
| E2 | 분리배출(10 문장) | 100/100 | 100/100 | 94/100 | 56/100 | 96/100 | 50/100 | 96/100 | 88/100 |

**표 B7. 지시별 통과 횟수 (다른 예시, gpt-6-luna, 10 세트, 조건당 100 회 중)**

| 조건 | 예시 | 소제목 4 줄 | 문단 4 개 | 첫 문단 2 문장 | 느낌표 1 회 | 문단당 2~4 문장 | 전체 10~14 문장 | 해요체 | 첫 문장 20 자 |
|---|---|---|---|---|---|---|---|---|---|
| C00 | 없음 | 100/100 | 99/100 | 91/100 | 97/100 | 95/100 | 90/100 | 95/100 | 96/100 |
| C04 | 도서관(10 문장) | 100/100 | 100/100 | 100/100 | 100/100 | 100/100 | 96/100 | 99/100 | 100/100 |
| E1 | 헌 옷 수거(12 문장) | 100/100 | 100/100 | 95/100 | 100/100 | 98/100 | 95/100 | 94/100 | 100/100 |
| E2 | 분리배출(10 문장) | 100/100 | 100/100 | 96/100 | 100/100 | 97/100 | 96/100 | 97/100 | 100/100 |

## 부록 C. 재현 방법

재현 꾸러미(ZIP)의 README.md 에 자세한 절차가 있다. 요약하면 다음과 같다.

- 분석만 다시 하기: 꾸러미 최상위 폴더에서 python code/analyze.py 를 실행하면 data/set1~3/run_sheet.txt(저장된 300 개 응답)를 채점해 results/ 폴더의 표와 그림을 다시 만든다. 파이썬 3 표준 라이브러리만 필요하고, 그림은 matplotlib 이 있을 때 만든다.
- 반복·보강 실험 다시 하기: ext/README.md 의 순서대로 ext/code/run_ext.py 로 호출한다. Gemini 파트(R, V, M_m2, X, S, L, E)는 GEMINI_API_KEY, OpenAI 파트(M_gpt, M_gpt6, R_gpt6, X_gpt6, S_gpt6, D_gpt6, E_gpt6; D_gpt6 의 과제 파일은 make_tasks_D.py 로 만든다)는 OPENAI_API_KEY 와 --api openai 를 쓴다. 사실 점검은 ext/code/judge_facts.py(--target ALL 은 OpenAI, --target GPT6 은 Gemini 호출), 내용 질은 judge_quality.py, 분석은 analyze_ext.py, analyze_x.py, analyze_facts.py, content_check.py, 진행률은 progress.py 로 한다. 저장된 응답과 판정은 ext/data/ 에 있다. 모델이 갱신되면 같은 호출을 그대로 다시 할 수 없을 수 있다.
- 호출부터 다시 하기: Gemini API 키를 환경변수 GEMINI_API_KEY 로 두고 code/make_run_sheet.py 로 빈 실행 기록을 만든 뒤 code/run_gemini.py --model gemini-3.5-flash-lite 를 실행한다. 채워진 칸은 건너뛰므로 중간에 멈춰도 이어서 할 수 있다. 응답은 호출마다 달라지므로 같은 숫자가 나오지는 않고, 분석은 저장된 응답으로 다시 만들 수 있다.

## 부록 D. 예비 실험과 설계 변경 기록

기본 조건의 난이도를 조정하는 데 여러 단계가 있었다 . 1~3 단계와 5~6 단계의 지시 조정은 기본 조건 응답만 보고 했다. 4 단계는 요소 조건까지 포함한 본 실험 결과를 본 뒤 설계를 바꾼 것이다.

**표 D1. 예비 실험과 설계 변경 기록**

| 단계 | 무엇을 했나 | 결과 | 조치 |
|---|---|---|---|
| 0 | Gemini 웹 화면에서 한 과제로 손으로 시험(요소 조건 일부 포함 아님) | 기본 준수율 85~100%로 천장에 닿음 | 지시를 늘리고 과제 10 개의 다과제 설계, API 호출로 전환 |
| 1 | 줄 수 목표 100·150·200 줄 비교(기본만, 지시 9 개, 각 10 회) | 82.2% / 84.4% / 86.7%. 문장마다 줄을 나눠 줄 수만 맞춤 | 100 줄 채택, 글자 수 기준으로 대체 검토 |
| 2 | 문단·줄 길이 지시 2 개 추가(지시 11 개, 기본 10 회) | 87.3%. 모델이 규칙을 잘 지켜 오히려 상승 | 두 지시 폐기 |
| 3 | 글자 수 기준과 문체 지시 2 개로 교체(지시 11 개, 기본 10 회) | 75.5% | 이 판으로 본 실험 A 실시 |
| 4 | 본 실험 A(300 회, 조건당 30 회) | 기본 77.9%. 모든 요소가 기본과 구분되지 않음(최대 +2.1%p, 구간 모두 0 포함). 분량 지시 2%, 어미 반복 금지 14%만 통과, 나머지 9 개는 87~100% | 측정 감도 부족으로 판단해 설계 교체. A 는 예비 실험으로 취급 |

| 단계 | 무엇을 했나 | 결과 | 조치 |
|---|---|---|---|
| 5 | 후보 지시 28 개를 기본 조건만으로 점검 (14 개씩 2 회, 각 30 건) | 1 차 4 개, 2 차 8 개가 통과율 30~75% 범위 | 2 차의 8 개를 기본 지시로 확정, 과제 2 번을 회의록에서 이메일로 변경(목록형 출력이라 문장 규칙이 거의 항상 실패) |
| 6 | 확정 설계의 기본 조건 30 건 | 73.3% (세트별 77.5 / 71.2 / 71.2%) | 고정하고 본 실험 B 실시(이 논문의 결과) |

이 보고의 결과(3 장)는 단계 6 이후의 본 실험 B 300 회다. 단계 6 의 기본 30 건은 본 실험 B 의 기본 조건 데이터로 그대로 쓰였고, 같은 프롬프트로 나머지 270 건을 이어서 호출했다.